L'IA vocale et nos langues

Module 1 — Session 1 · Partie A : panorama

Fondamentaux de l'IA vocale et des langues locales

Dr Fréjus A. A. Laleye · 15 octobre 2026

Bienvenue !

- 4 sessions, 6 séances de 3 h, **très pratiques**
- Un fil rouge : **votre langue**, de la voix au texte
- Un public **mixte** : c'est une force
- Objectif : des **compétences**, pas seulement des connaissances

? Qui êtes-vous ?

Sondage (Zoom / Wooclap) — 1 minute

1. Mon profil : dév · data/ML · linguiste · chef·fe de projet · acteur sectoriel · étudiant·e
2. Les langues que je **parle** : fongbe · wolof · autre langue locale · aucune
3. Mon aisance en Python : 1 → 5

Le programme en 4 modules

Module	Thème	Format
1	**Fondamentaux** : signal, phonétique, ASR/TTS, données	6 séances de 3 h, Zoom
2	Fine-tuning (Whisper), évaluation, LLM, applications	Zoom
3	Déploiement & MLOps	Zoom
4	Solutions de bout en bout, open source, **hackathon**	Cotonou

Le Module 1 en 4 sessions

Session	Thème	Vous repartez avec…
S1	Panorama & phonétique	vos premières transcriptions, vos enregistrements
S2	Traitement du signal	un pipeline de nettoyage audio
S3 (3 séances)	Reconnaissance vocale (ASR)	un Transformer reconstruit, un banc d'essai de modèles
S4	Corpus, Hugging Face, mini-projet	votre corpus publié + une démo

🧵 Le fil rouge : « Ma langue, de la voix au texte »

Un assistant vocal = une chaîne de briques (en orange : le cœur du Module 1)



TP1 enregistrer → **TP2** nettoyer → **TP3** transcrire → **TP4** publier un corpus → **Module 2** fine-tuner

Comment on travaille

- 🟢 **Essentiel** : exécuter, observer, interpréter — *tout le monde*
- 🔵 **Intermédiaire** : compléter du code guidé
- 🔴 **Avancé** : défis ouverts, optionnels
- Binômes **pilote** (tape) / **navigateur** (lit, interprète) — on inverse à chaque atelier
- Le chat **SOS** est surveillé par les assistants

🎯 Objectifs de la session 1

À la fin de la session, vous saurez :

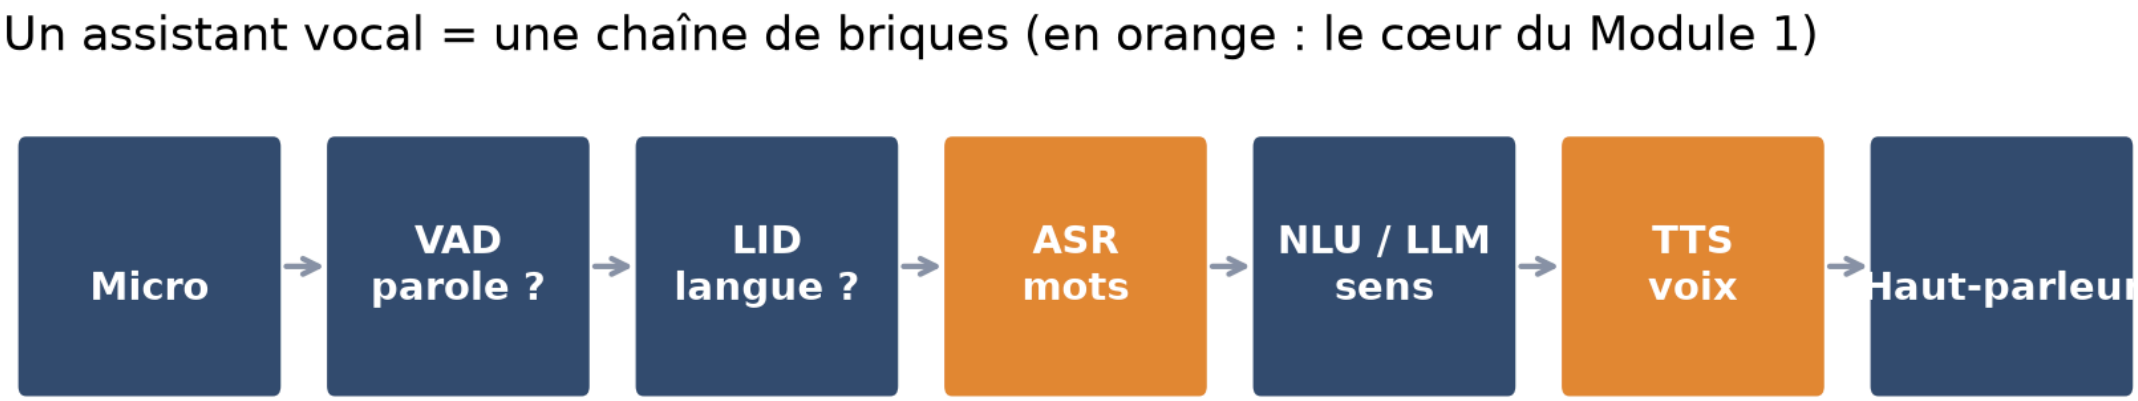
1. **Décrire** la chaîne de la parole et situer l'état de l'art
2. **Expliquer** ce qu'est une langue « peu dotée » (fongbe, wolof)
3. **Lancer** une transcription (ASR) et une synthèse (TTS) — et en voir les limites
4. **Transcrire** des sons avec l'API ; expliquer tons, nasalité, longueur
5. **Visualiser** un ton et **normaliser** un texte (Unicode)

1. La chaîne de la parole

L'IA vocale = des briques

Tâche	Entrée → sortie	Exemple
ASR — reconnaissance	audio → texte	sous-titrer une radio wolof
TTS — synthèse	texte → audio	alerte météo lue en fongbe
LID — identification de langue	audio → langue	router un appel
Traduction de la parole	audio → texte/audio (autre langue)	consultation fon → français
Diarisation	audio → qui parle quand	débat radio
KWS — mots-clés	audio → mot détecté	repérer « paludisme »

Un assistant vocal enchaîne les briques

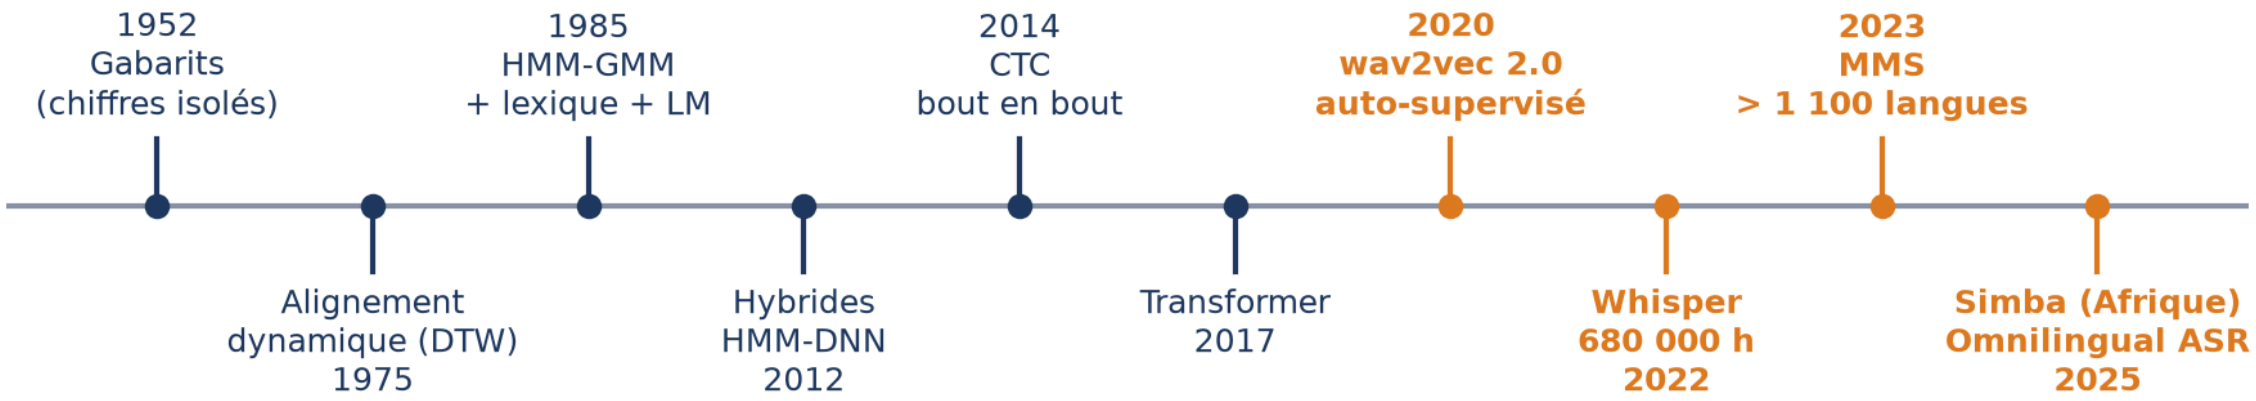


⚠️ Les erreurs **s'additionnent** : une ASR à 30 % d'erreurs sur les mots rend la compréhension très difficile.

2. Soixante-dix ans de reconnaissance vocale

De la règle à l'apprentissage auto-supervisé

Soixante-dix ans de reconnaissance vocale (en orange : l'ère auto-supervisée et multilingue)



Le tournant pour les langues peu dotées

Avant (≈ 2014–2019) : des **milliers d'heures transcrites** nécessaires

Aujourd'hui : apprentissage **auto-supervisé**

1. Le modèle écoute des heures d'audio **non transcrit** (comme un enfant qui écoute avant de parler)
2. On l'**affine** (*fine-tuning*) avec **quelques heures** transcrites

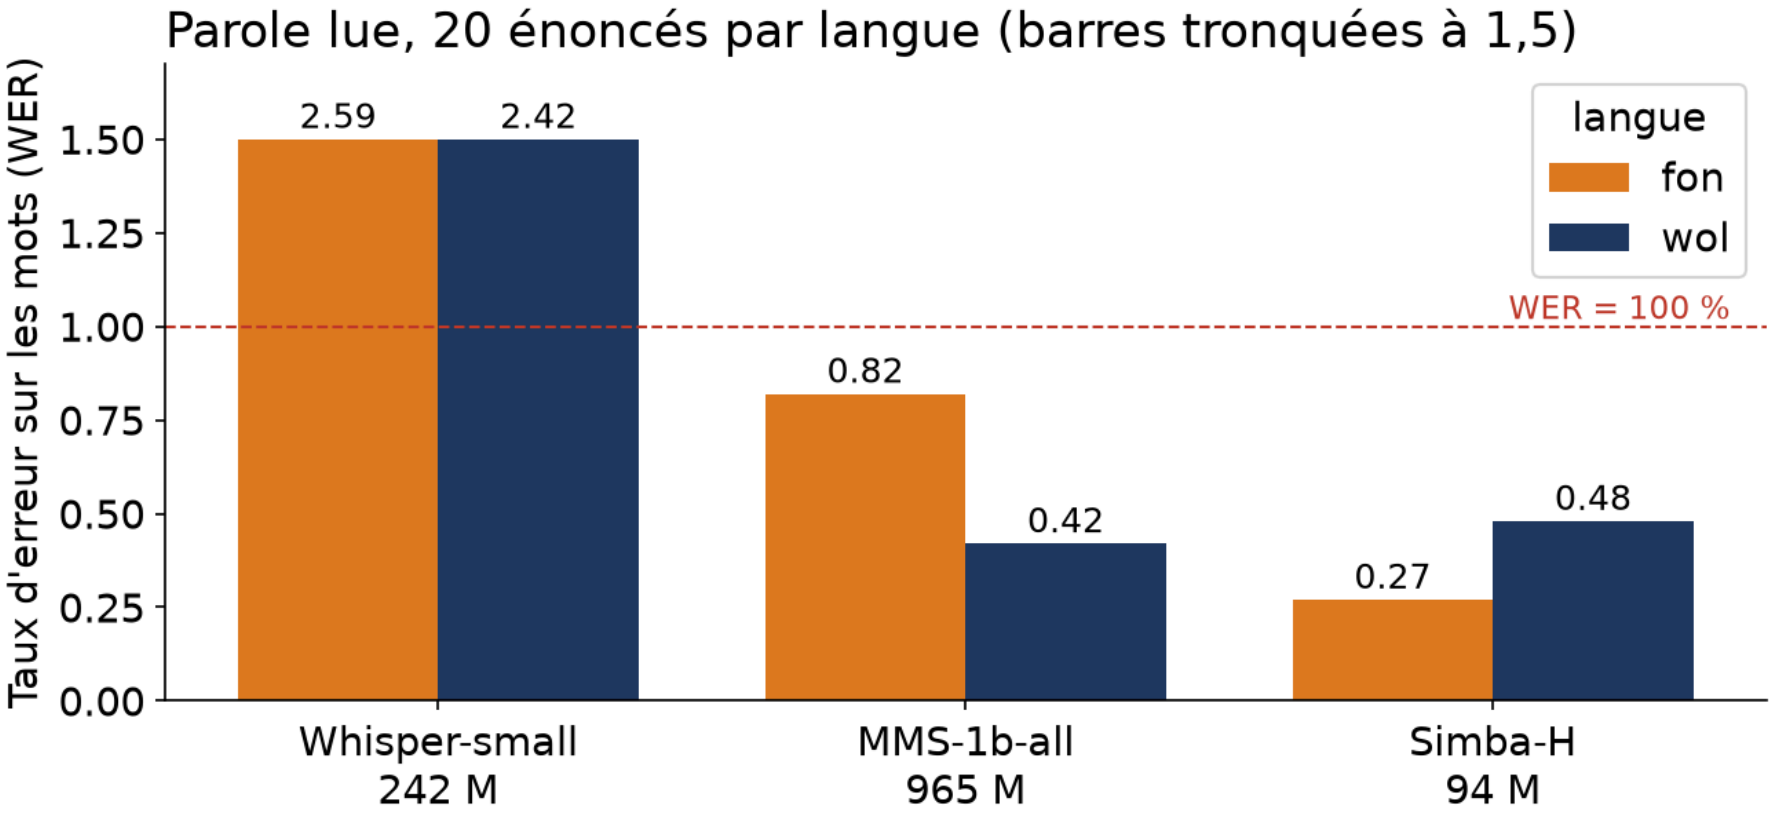
➡️ C'est exactement ce que vous ferez au **Module 2**

3. L'état de l'art en 2026

Trois familles de modèles

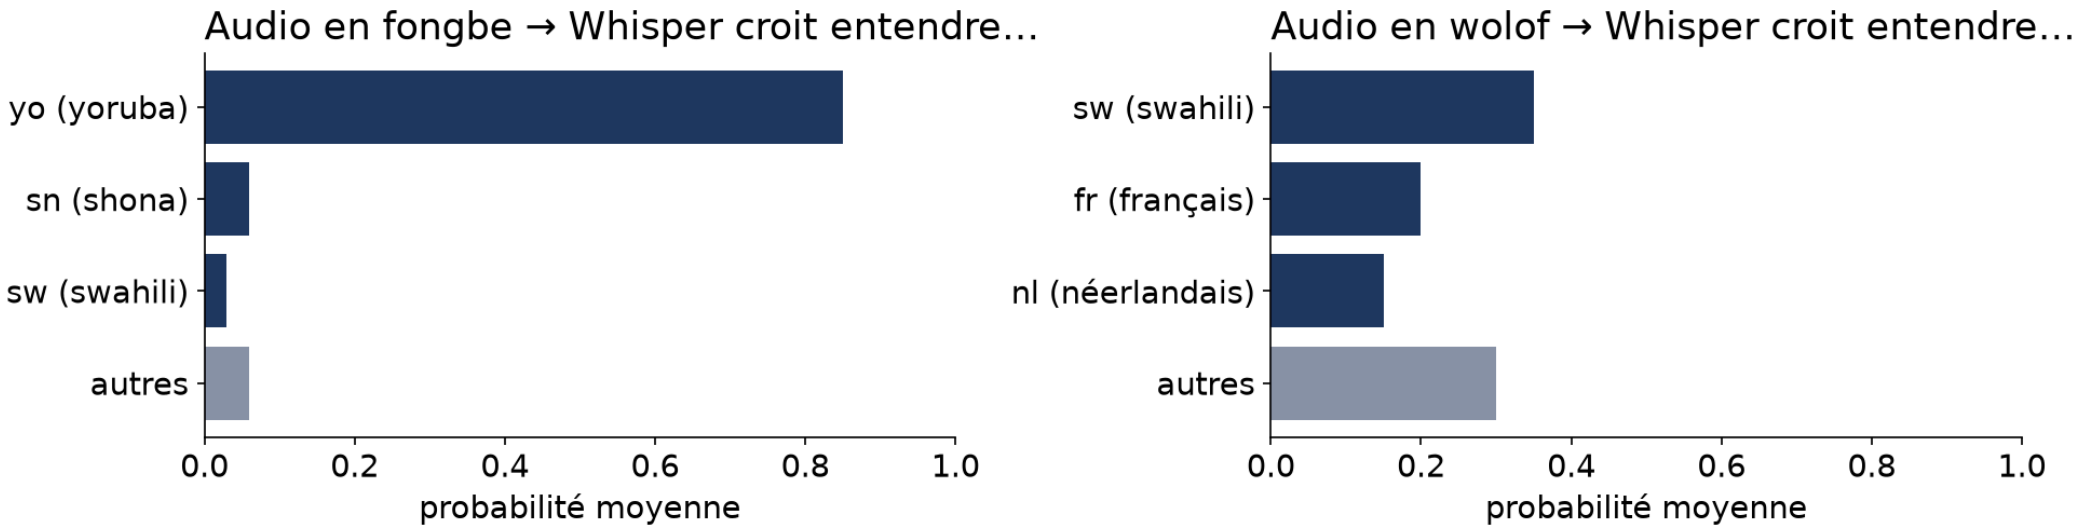
Famille	Exemple	Couverture	Fongbe / wolof ?
Généraliste	Whisper (OpenAI, 2022) — 680 000 h	≈ 100 langues	❌ ni l'un ni l'autre
Massivement multilingue	MMS (Meta, 2023) ; Omnilingual ASR (2025)	> 1 100 / > 1 600 langues	✅ via un adaptateur
Spécialisé Afrique	Simba (EMNLP 2025)	43 langues africaines	✅

Ce que nous avons mesuré



WER = taux d'erreur sur les mots (0 = parfait, > 1 = le modèle invente)

Whisper : quand un géant hallucine



Puis il **écrit** dans la langue qu'il croit entendre : yoruba, arabe, hébreu… ou boucle `ọ ọ ọ ọ`

? Question éclair

Whisper a été entraîné sur 680 000 heures. Pourquoi échoue-t-il sur le fongbe ?

- A. Le fongbe est trop difficile à reconnaître
- B. Le fongbe ne fait pas partie de ses langues d'entraînement
- C. L'audio est de mauvaise qualité
- D. Whisper ne connaît que l'anglais

4. Les langues « peu dotées »

« Peu doté » ≠ « peu parlé »

Critère	Français	Fongbe
Parole transcrite disponible	dizaines de milliers d'h	quelques dizaines d'h
Textes numériques	milliards de mots	très peu, souvent **sans tons**
Orthographe pratiquée à l'écrit	oui	officielle mais peu pratiquée
Outils (claviers, correcteurs)	nombreux	rares
Présence dans les grands modèles	systématique	rare

Un écosystème qui se structure

- **ALFFA** : premiers corpus ASR publics fongbe et wolof (2016)
- **Masakhane** : communauté de recherche en langues africaines
- **Lacuna Fund** : financement de données (ex. **Kallaama**, wolof agricole)
- **SimbaBench** (2025) : banc d'essai unifié pour 40+ langues africaines

Nos données de cours viennent de ces projets — **licences ouvertes, citées**.

5. Le fongbe et le wolof

Carte d'identité

Fongbe (`fon`)

- Bénin (sud), Togo — famille gbe
- **Langue à tons** (haut, bas, contours)
- Lettres ɛ, ɔ, ɖ ; *kp*, *gb*
- Voyelles **nasales** (*an, ɛn, ɔn*)
- Tons **rarement écrits**

Wolof (`wol`)

- Sénégal, Gambie, Mauritanie
- **Pas de tons**
- **Durées** distinctives : *fen / feen*, *bët / bëtt*
- Lettres ë, ñ, ŋ, x ; *mb, nd*
- Graphie officielle vs francisée

Les deux : **code-switching** fréquent avec le français.

6. Cas d'usage et impact

Où la voix change la donne

Secteur	Exemple	Coût d'une erreur
Santé	rappel de traitement vocal en fongbe	**élevé**
Agriculture	prix et météo par serveur vocal (IVR) en wolof	moyen
Finance mobile	transfert par commande vocale	**élevé** (fraude)
Éducation	lecture assistée en langue maternelle	moyen
Médias	sous-titrage de radios locales	faible

Succès = **utilisateurs** + **canal** (téléphone 8 kHz ?) + **qualité requise** + **données** + **éthique**

📌 À retenir — panorama

- L'IA vocale = des **briques** dont les erreurs s'additionnent
- L'**auto-supervisé** a ouvert la porte aux langues peu dotées
- Un géant généraliste **hallucine** sur une langue qu'il ne connaît pas
- **Spécialisé > gros** : Simba-H (94 M) bat Whisper (242 M) et MMS (965 M) en fongbe
- Le succès d'un projet dépend d'abord des **usages** et des **données**

🛠️ Atelier 1A — Premier contact

Notebook : `S1_NB01_premier_contact` · **30 min** · binômes pilote / navigateur

1. Écouter fongbe, wolof, français (lu, spontané, téléphone)
2. 🟢 Whisper sur le français… puis sur le fongbe et le wolof : **que se passe-t-il ?**
3. 🟢 MMS et Simba-H ; 🔵 mesurer l'erreur (CER)
4. 🟢 Synthèse vocale fongbe et wolof ; 🔵 avec / sans tons
5. 🔴 Boucle TTS → ASR

Livrable : le tableau « ce qui marche / ce qui ne marche pas » (fin du notebook)

🛠️ TD1 partie A — Canvas cas d'usage

Breakout rooms de 3–4, profils mixtes · 18 min + 7 min de restitution

1. Choisir **un scénario** parmi les 8 du TD1 (santé, agriculture, finance…)
2. Remplir le **canvas** (10 blocs) dans le document partagé
3. Préparer un **pitch d'1 minute**

Rôles : animateur·rice · secrétaire · porte-parole · gardien·ne du temps

☕ Pause — 10 minutes

Reprise à **1:40** : « Voir et écrire les sons »

📚 Pour aller plus loin

- Radford et al. (2022). *Robust Speech Recognition via Large-Scale Weak Supervision* (Whisper)
- Pratap et al. (2023). *Scaling Speech Technology to 1,000+ Languages* (MMS)
- Elmadany et al. (2025). *Voice of a Continent: Mapping Africa's Speech Technology Frontier* (Simba)
- Cours audio Hugging Face : huggingface.co/learn/audio-course

Support écrit : `module1/session1/cours/S1_cours.md` §1–7