# L'IA vocale et nos langues

## Module 1 — Session 1 · Partie A : panorama

Fondamentaux de l'IA vocale et des langues locales

Dr Fréjus A. A. Laleye · 15 octobre 2026

# Bienvenue !

- 4 sessions, 6 séances de 3 h, **très pratiques**
- Un fil rouge : **votre langue**, de la voix au texte
- Un public **mixte** : c'est une force
- Objectif : des **compétences**, pas seulement des connaissances

# ? Qui êtes-vous ?

**Sondage (Zoom / Wooclap) — 1 minute**

1. Mon profil : dév · data/ML · linguiste · chef·fe de projet · acteur sectoriel · étudiant·e
2. Les langues que je **parle** : fongbe · wolof · autre langue locale · aucune
3. Mon aisance en Python : 1 → 5

# Le programme en 4 modules

| Module | Thème | Format |
|---|---|---|
| **1** | **Fondamentaux** : signal, phonétique, ASR/TTS, données | 6 séances de 3 h, Zoom |
| 2 | Fine-tuning (Whisper), évaluation, LLM, applications | Zoom |
| 3 | Déploiement & MLOps | Zoom |
| 4 | Solutions de bout en bout, open source, **hackathon** | Cotonou |

# Le Module 1 en 4 sessions

| Session | Thème | Vous repartez avec… |
|---|---|---|
| **S1** | Panorama & phonétique | vos premières transcriptions, vos enregistrements |
| S2 | Traitement du signal | un pipeline de nettoyage audio |
| S3 (3 séances) | Reconnaissance vocale (ASR) | un Transformer reconstruit, un banc d'essai de modèles |
| S4 | Corpus, Hugging Face, mini-projet | votre corpus publié + une démo |

# 🧵 Le fil rouge : « Ma langue, de la voix au texte »

Un assistant vocal = une chaîne de briques (en orange : le cœur du Module 1)




**TP1** enregistrer → **TP2** nettoyer → **TP3** transcrire → **TP4** publier un corpus → **Module 2** fine-tuner

# Comment on travaille

- 🟢 **Essentiel** : exécuter, observer, interpréter — *tout le monde*
- 🔵 **Intermédiaire** : compléter du code guidé
- 🔴 **Avancé** : défis ouverts, optionnels
- Binômes **pilote** (tape) / **navigateur** (lit, interprète) — on inverse à chaque atelier
- Le chat **SOS** est surveillé par les assistants

# 🎯 Objectifs de la session 1

À la fin de la session, vous saurez :

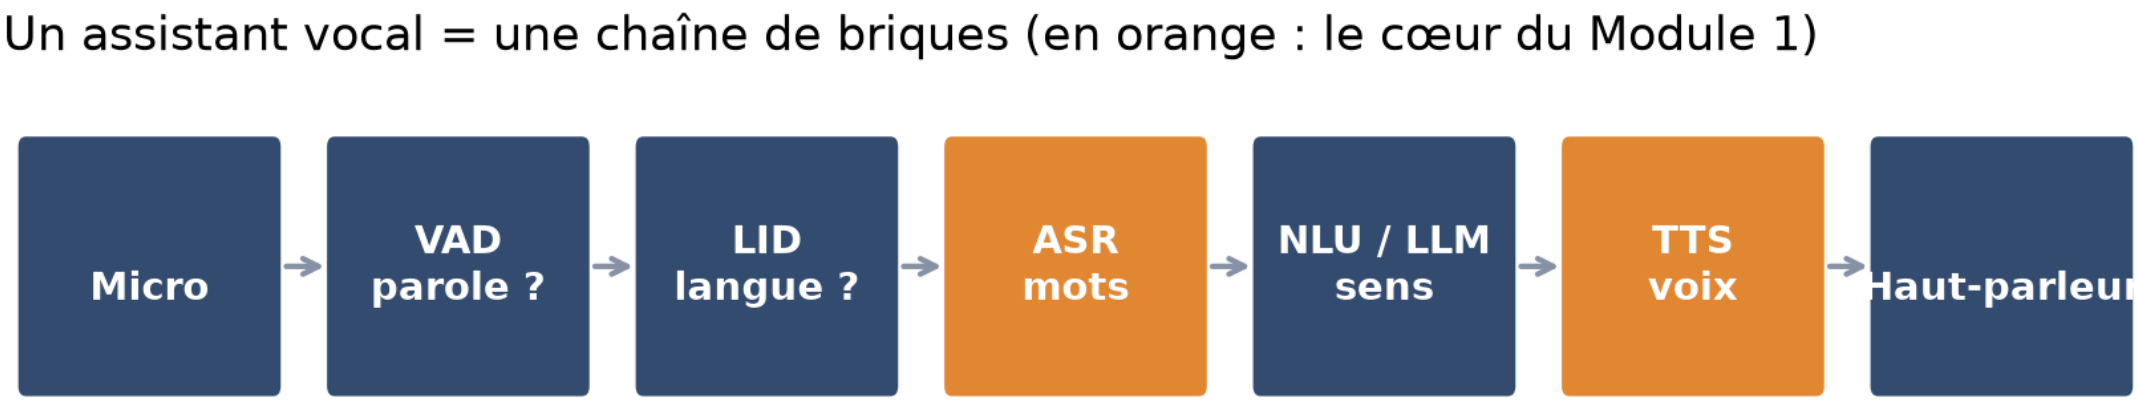
1. **Décrire** la chaîne de la parole et situer l'état de l'art
2. **Expliquer** ce qu'est une langue « peu dotée » (fongbe, wolof)
3. **Lancer** une transcription (ASR) et une synthèse (TTS) — et en voir les limites
4. **Transcrire** des sons avec l'API ; expliquer tons, nasalité, longueur
5. **Visualiser** un ton et **normaliser** un texte (Unicode)

# 1. La chaîne de la parole

# L'IA vocale = des briques

| Tâche | Entrée → sortie | Exemple |
|---|---|---|
| **ASR** — reconnaissance | audio → texte | sous-titrer une radio wolof |
| **TTS** — synthèse | texte → audio | alerte météo lue en fongbe |
| **LID** — identification de langue | audio → langue | router un appel |
| Traduction de la parole | audio → texte/audio (autre langue) | consultation fon → français |
| Diarisation | audio → qui parle quand | débat radio |
| KWS — mots-clés | audio → mot détecté | repérer « paludisme » |

# Un assistant vocal enchaîne les briques

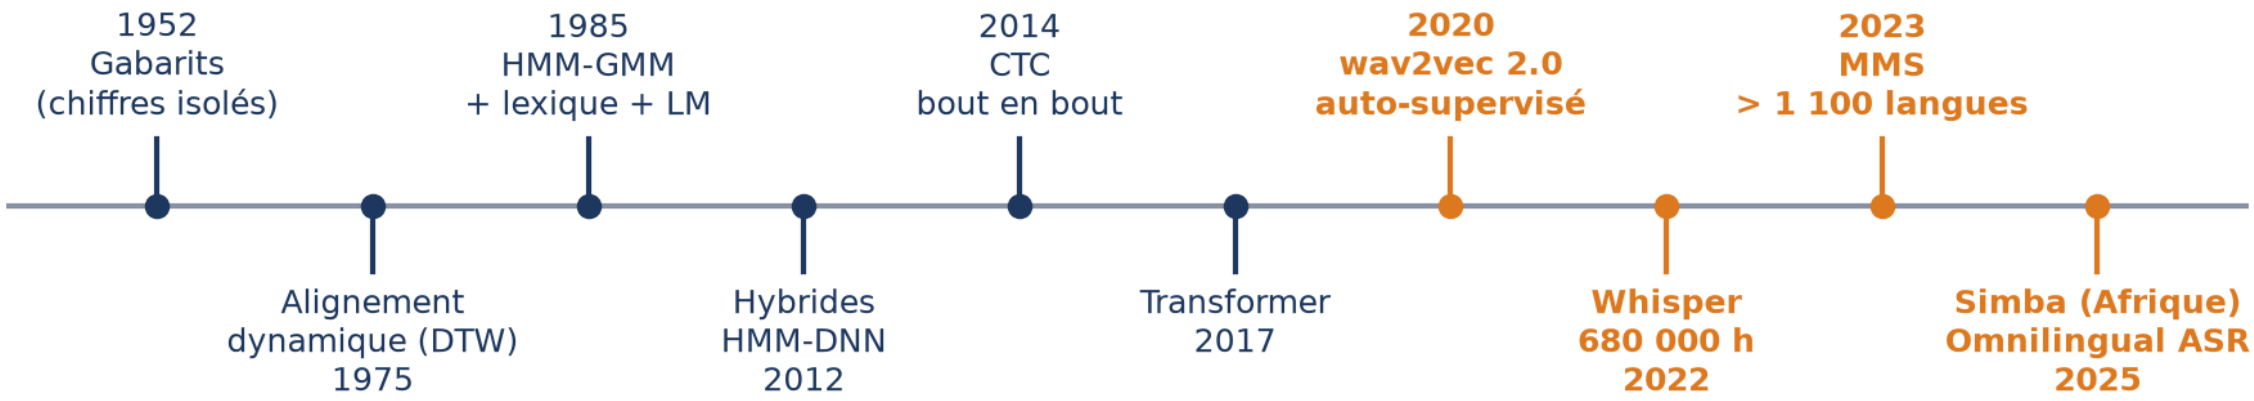



⚠️ Les erreurs **s'additionnent** : une ASR à 30 % d'erreurs sur les mots rend la compréhension très difficile.

# 2. Soixante-dix ans de reconnaissance vocale

# De la règle à l'apprentissage auto-supervisé

Soixante-dix ans de reconnaissance vocale (en orange : l'ère auto-supervisée et multilingue)



# Le tournant pour les langues peu dotées

**Avant (≈ 2014–2019)** : des **milliers d'heures transcrites** nécessaires

**Aujourd'hui** : apprentissage **auto-supervisé**

1. Le modèle écoute des heures d'audio **non transcrit** (comme un enfant qui écoute avant de parler)
2. On l'**affine** (*fine-tuning*) avec **quelques heures** transcrites

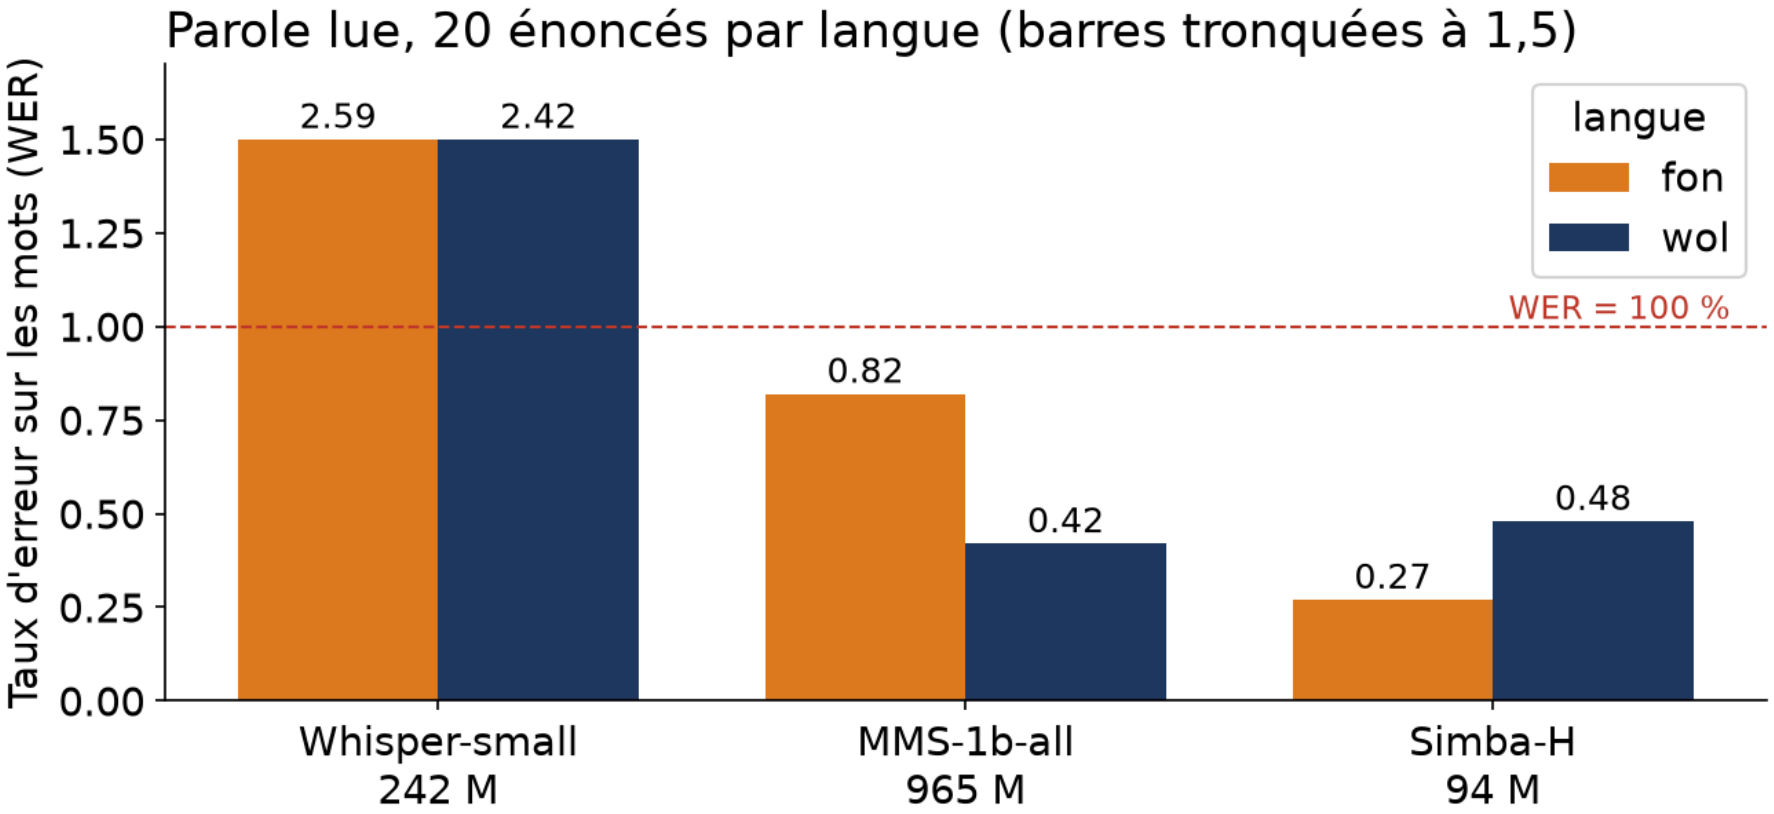
➡️ C'est exactement ce que vous ferez au **Module 2**

# 3. L'état de l'art en 2026

# Trois familles de modèles

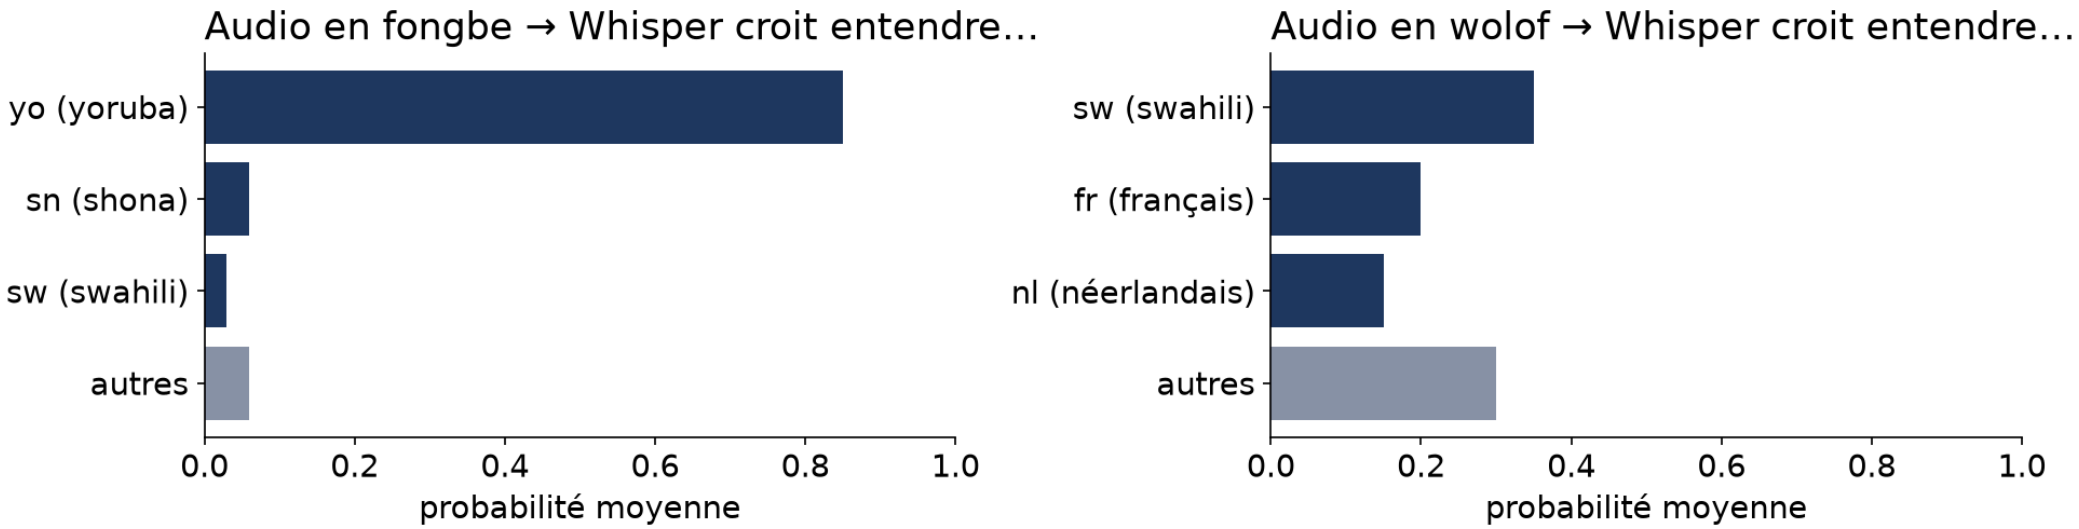
| Famille | Exemple | Couverture | Fongbe / wolof ? |
|---|---|---|---|
| **Généraliste** | Whisper (OpenAI, 2022) — 680 000 h | ≈ 100 langues | ❌ ni l'un ni l'autre |
| **Massivement multilingue** | MMS (Meta, 2023) ; Omnilingual ASR (2025) | > 1 100 / > 1 600 langues | ✅ via un adaptateur |
| **Spécialisé Afrique** | Simba (EMNLP 2025) | 43 langues africaines | ✅ |

# Ce que nous avons mesuré




WER = taux d'erreur sur les mots (0 = parfait, > 1 = le modèle invente)

# Whisper : quand un géant hallucine




Puis il **écrit** dans la langue qu'il croit entendre : yoruba, arabe, hébreu… ou boucle `ọ ọ ọ ọ`

# ? Question éclair

Whisper a été entraîné sur 680 000 heures. Pourquoi échoue-t-il sur le fongbe ?

- A. Le fongbe est trop difficile à reconnaître
- B. Le fongbe ne fait pas partie de ses langues d'entraînement
- C. L'audio est de mauvaise qualité
- D. Whisper ne connaît que l'anglais

# 4. Les langues « peu dotées »

# « Peu doté » ≠ « peu parlé »

| Critère | Français | Fongbe |
|---|---|---|
| Parole transcrite disponible | dizaines de milliers d'h | quelques dizaines d'h |
| Textes numériques | milliards de mots | très peu, souvent **sans tons** |
| Orthographe pratiquée à l'écrit | oui | officielle mais peu pratiquée |
| Outils (claviers, correcteurs) | nombreux | rares |
| Présence dans les grands modèles | systématique | rare |

# Un écosystème qui se structure

- **ALFFA** : premiers corpus ASR publics fongbe et wolof (2016)
- **Masakhane** : communauté de recherche en langues africaines
- **Lacuna Fund** : financement de données (ex. **Kallaama**, wolof agricole)
- **SimbaBench** (2025) : banc d'essai unifié pour 40+ langues africaines

Nos données de cours viennent de ces projets — **licences ouvertes, citées**.

# 5. Le fongbe et le wolof

# Carte d'identité

**Fongbe** ( `fon` )

- Bénin (sud), Togo — famille gbe
- **Langue à tons** (haut, bas, contours)
- Lettres ɛ, ɔ, ɖ ; *kp*, *gb*
- Voyelles **nasales** (*an, ɛn, ɔn*)
- Tons **rarement écrits**

**Wolof** ( `wol` )

- Sénégal, Gambie, Mauritanie
- **Pas de tons**
- **Durées** distinctives : *fen / feen*, *bët / bëtt*
- Lettres ë, ñ, ŋ, x ; *mb, nd*
- Graphie officielle vs francisée

Les deux : **code-switching** fréquent avec le français.

# 6. Cas d'usage et impact

# Où la voix change la donne

| Secteur | Exemple | Coût d'une erreur |
|---|---|---|
| Santé | rappel de traitement vocal en fongbe | **élevé** |
| Agriculture | prix et météo par serveur vocal (IVR) en wolof | moyen |
| Finance mobile | transfert par commande vocale | **élevé** (fraude) |
| Éducation | lecture assistée en langue maternelle | moyen |
| Médias | sous-titrage de radios locales | faible |

Succès = **utilisateurs** + **canal** (téléphone 8 kHz ?) + **qualité requise** + **données** + **éthique**

# 📌 À retenir — panorama

- L'IA vocale = des **briques** dont les erreurs s'additionnent
- L'**auto-supervisé** a ouvert la porte aux langues peu dotées
- Un géant généraliste **hallucine** sur une langue qu'il ne connaît pas
- **Spécialisé > gros** : Simba-H (94 M) bat Whisper (242 M) et MMS (965 M) en fongbe
- Le succès d'un projet dépend d'abord des **usages** et des **données**

# 🛠️ Atelier 1A — Premier contact

**Notebook :** `S1_NB01_premier_contact` · **30 min** · binômes pilote / navigateur

1. Écouter fongbe, wolof, français (lu, spontané, téléphone)
2. 🟢 Whisper sur le français… puis sur le fongbe et le wolof : **que se passe-t-il ?**
3. 🟢 MMS et Simba-H ; 🔵 mesurer l'erreur (CER)
4. 🟢 Synthèse vocale fongbe et wolof ; 🔵 avec / sans tons
5. 🔴 Boucle TTS → ASR

**Livrable** : le tableau « ce qui marche / ce qui ne marche pas » (fin du notebook)

# 🛠️ TD1 partie A — Canvas cas d'usage

**Breakout rooms de 3–4, profils mixtes · 18 min + 7 min de restitution**

1. Choisir **un scénario** parmi les 8 du TD1 (santé, agriculture, finance…)
2. Remplir le **canvas** (10 blocs) dans le document partagé
3. Préparer un **pitch d'1 minute**

Rôles : animateur·rice · secrétaire · porte-parole · gardien·ne du temps

# ☕ Pause — 10 minutes

Reprise à **1:40** : « Voir et écrire les sons »

# 📚 Pour aller plus loin

- Radford et al. (2022). *Robust Speech Recognition via Large-Scale Weak Supervision* (Whisper)
- Pratap et al. (2023). *Scaling Speech Technology to 1,000+ Languages* (MMS)
- Elmadany et al. (2025). *Voice of a Continent: Mapping Africa's Speech Technology Frontier* (Simba)
- Cours audio Hugging Face : huggingface.co/learn/audio-course

Support écrit : `module1/session1/cours/S1_cours.md` §1–7