Du son au spectrogramme

Module 1 — Session 2 · Partie A

Ce que l'ordinateur « entend » vraiment

? Quiz flash — rappel de la session 1

3 questions · 3 minutes · lien dans le chat

Vos enregistrements TP1 : retour

- **[N]** participants · **[N]** fichiers · **[durée]** min de parole en fongbe, wolof, [autres]
- ✅ Ce qui marche : **[exemples]**
- ⚠️ Problèmes fréquents : saturation, ventilateur, fichiers stéréo à 44,1 kHz, nommage
- 🎯 Aujourd'hui : on **voit** et on **nettoie** ces enregistrements

🎯 Objectifs de la session 2

1. **Expliquer** la numérisation : échantillonnage, Nyquist, repliement, quantification
2. **Passer** au domaine fréquentiel : FFT, STFT, compromis temps/fréquence
3. **Lire** un spectrogramme (et ses défauts)
4. **Calculer** ce que voient les modèles : log-Mel, MFCC
5. **Construire** votre pipeline de prétraitement

1. Le son, une onde

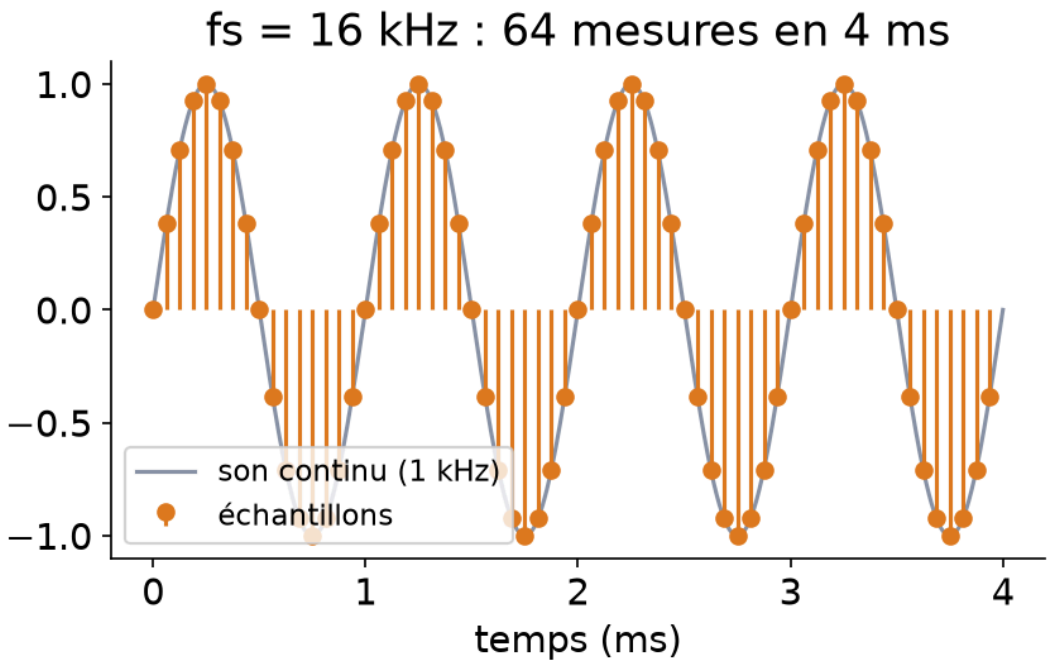
Pression, fréquence, amplitude

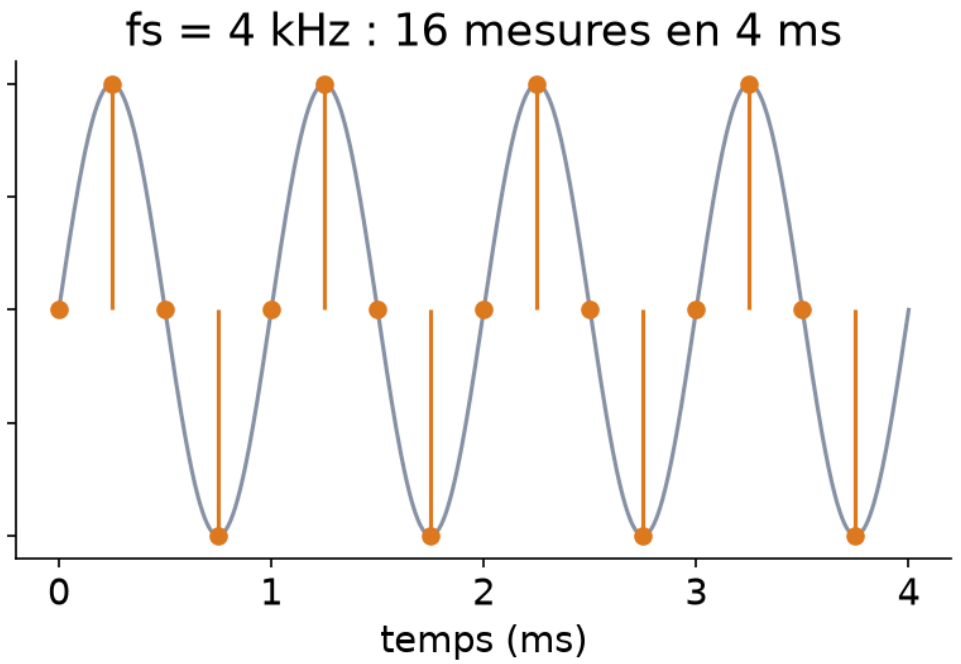
- Le son = une **variation de pression** de l'air
- **Fréquence** (Hz) = cycles par seconde → hauteur perçue
- **Amplitude** → volume perçu
- La parole = un son **complexe** : F0 + **harmoniques** (source) façonnées par les **formants** (filtre)

Utile pour la parole : **100 Hz – 8 kHz**

2. Numériser

Échantillonner = mesurer fs fois par seconde





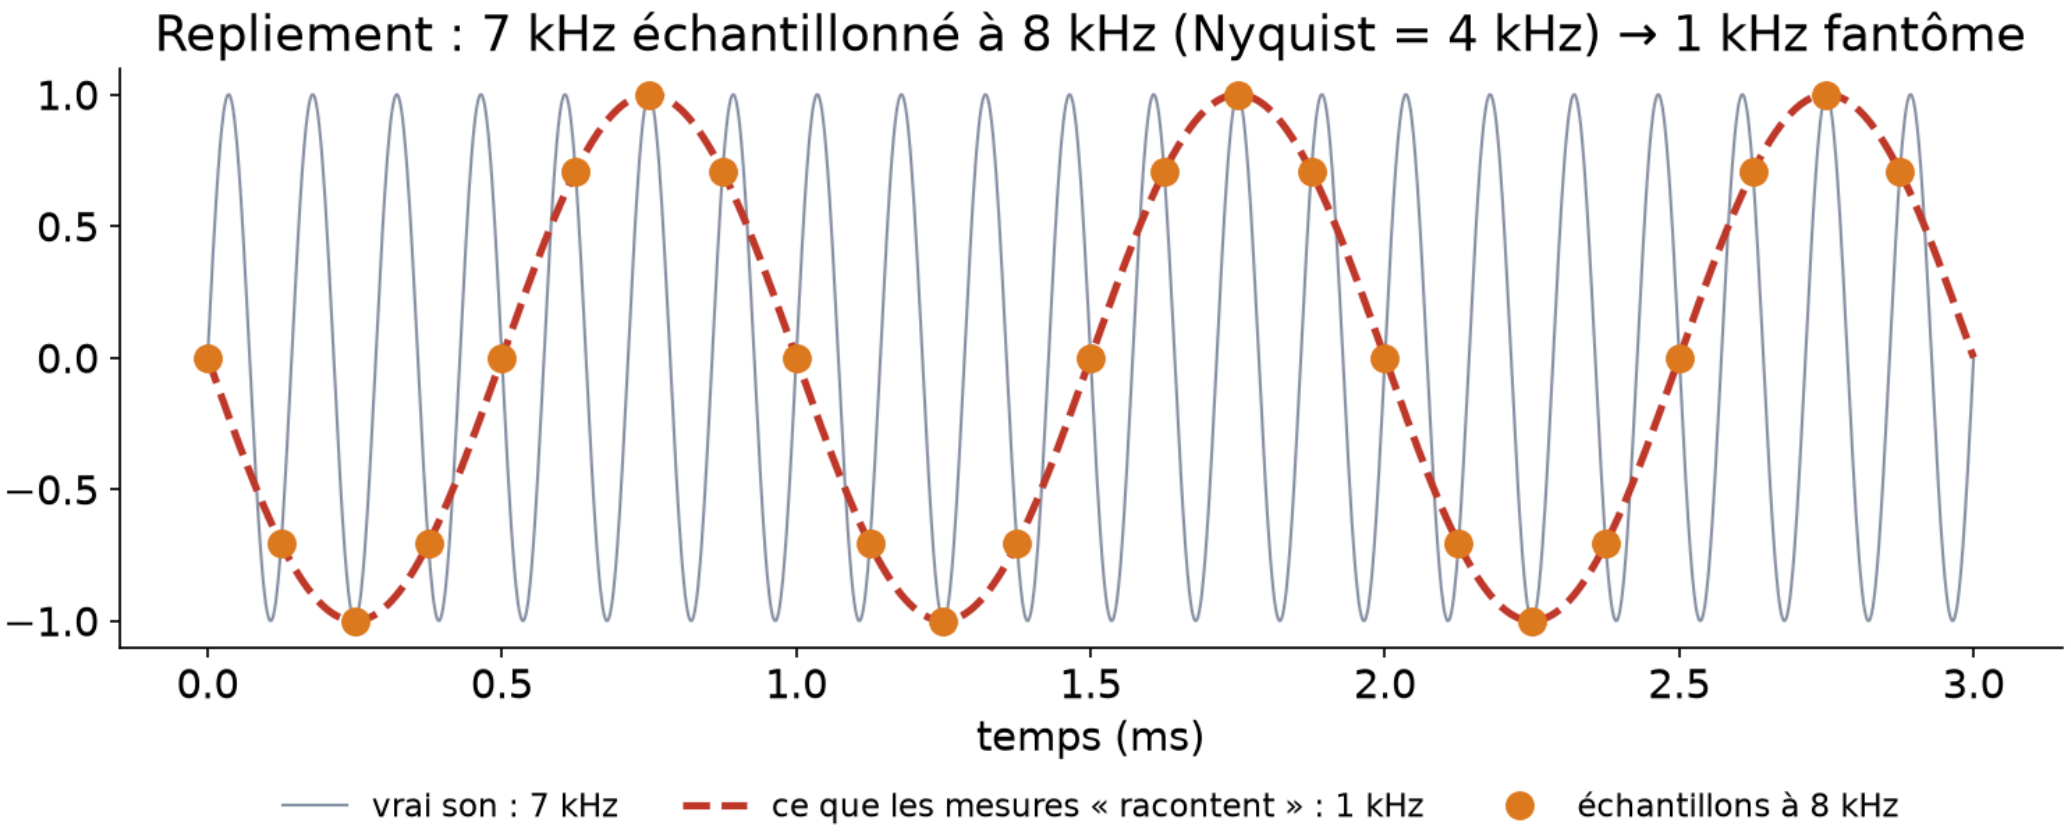
1 s de parole à 16 kHz = **16 000 nombres**

Nyquist-Shannon

On ne représente que les fréquences **< fs / 2**

fs	Nyquist	Usage
8 kHz	4 kHz	téléphone
16 kHz	**8 kHz**	**ASR** (tous nos modèles)
22–24 kHz	11–12 kHz	synthèse vocale
44,1 / 48 kHz	22 / 24 kHz	musique, vidéo, smartphone

Le repliement : un son fantôme



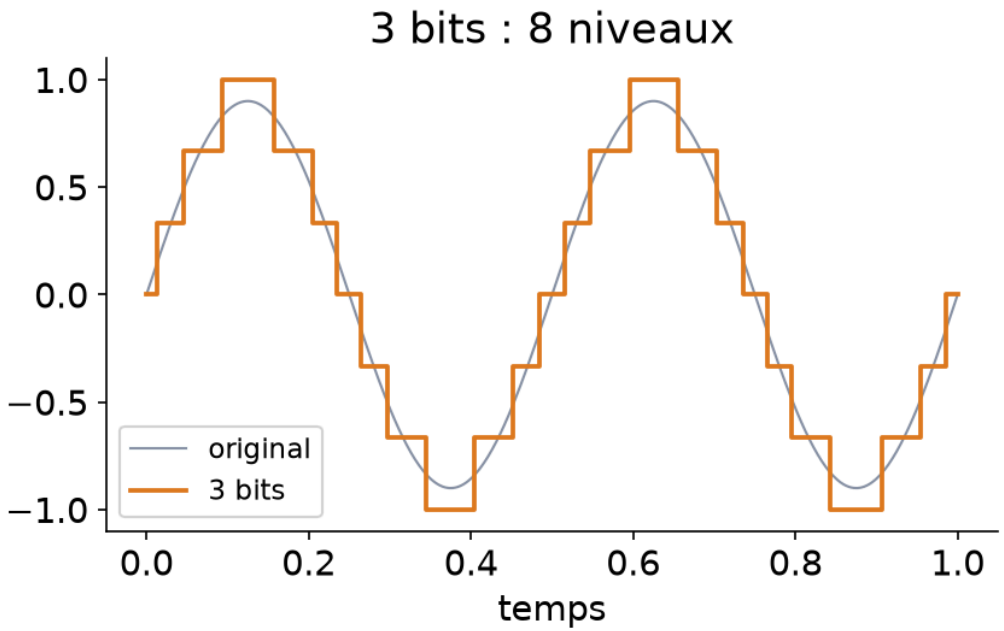
$f_{apparente} = |f - f_s \cdot \mathrm{round}(f/f_s)|$ → **filtre anti-repliement** avant de réduire fs

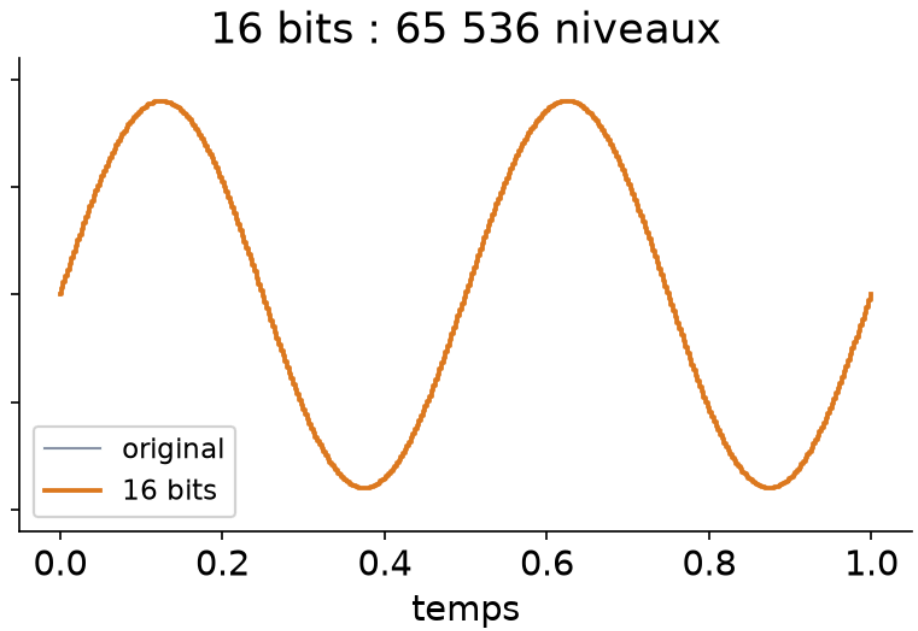
? Question éclair

Un son de 6 kHz est réduit **naïvement** à fs = 8 kHz. Quelle fréquence entend-on ?

- A. 6 kHz
- B. 4 kHz
- C. 2 kHz
- D. 14 kHz

Quantifier : n bits = 2^n niveaux





≈ **6 dB par bit** · 16 bits ≈ 96 dB de dynamique → largement assez pour la parole

dBFS et saturation

- Niveau mesuré par rapport à la **pleine échelle** : 0 dBFS = maximum → valeurs **négatives**
- Voix bien enregistrée : crête −6 à −1 dBFS · RMS −25 à −15 dBFS
- **Saturation** (écrêtage) : crêtes coupées à ±1 → grésillement → **irréversible** → réenregistrer

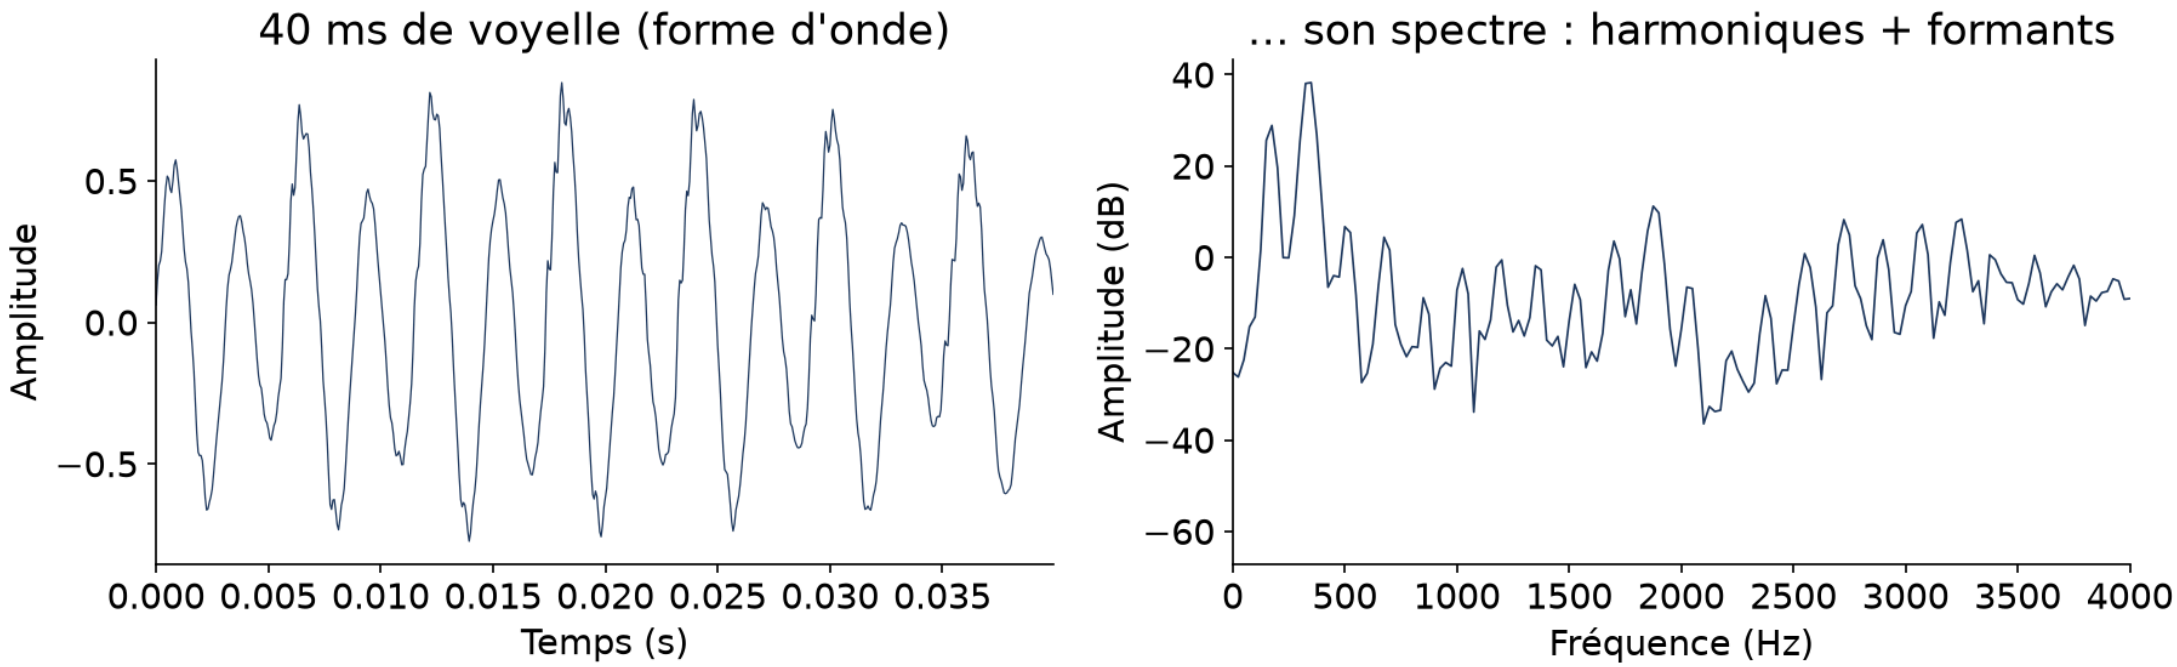
Formats et codecs

Format	Compression	Pour quoi ?
WAV (PCM)	aucune	travail
FLAC	sans perte	archiver un corpus
MP3, AAC (M4A)	avec perte	diffusion
Opus	avec perte	**notes vocales WhatsApp**
G.711, AMR	bande étroite	**téléphonie 8 kHz**

➡️ Collecter dans le **format et le canal de l'usage réel**

3. Le domaine fréquentiel

Fourier : le prisme du son

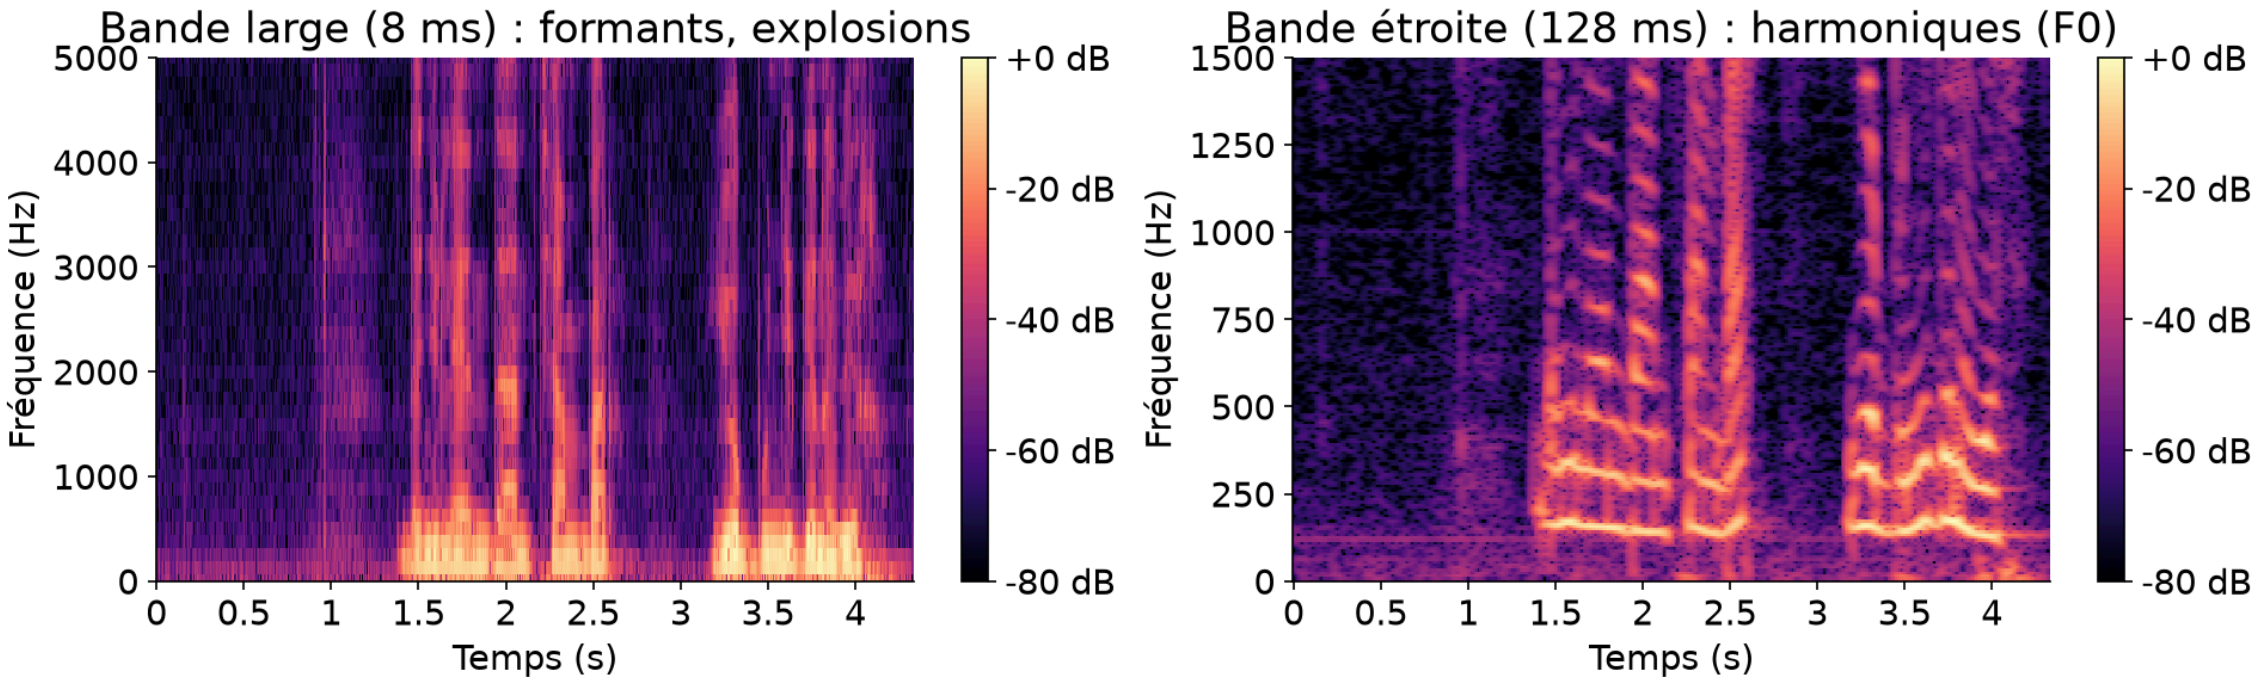


Harmoniques espacées de F0 (source) · **enveloppe** = formants (filtre)

La STFT : Fourier sur des fenêtres glissantes

- Fenêtre de **25 ms** (400 échantillons), pas de **10 ms** → **100 trames / s**
- Fenêtre de Hann pour adoucir les bords
- On empile les spectres → **spectrogramme** (temps × fréquence × énergie en dB)

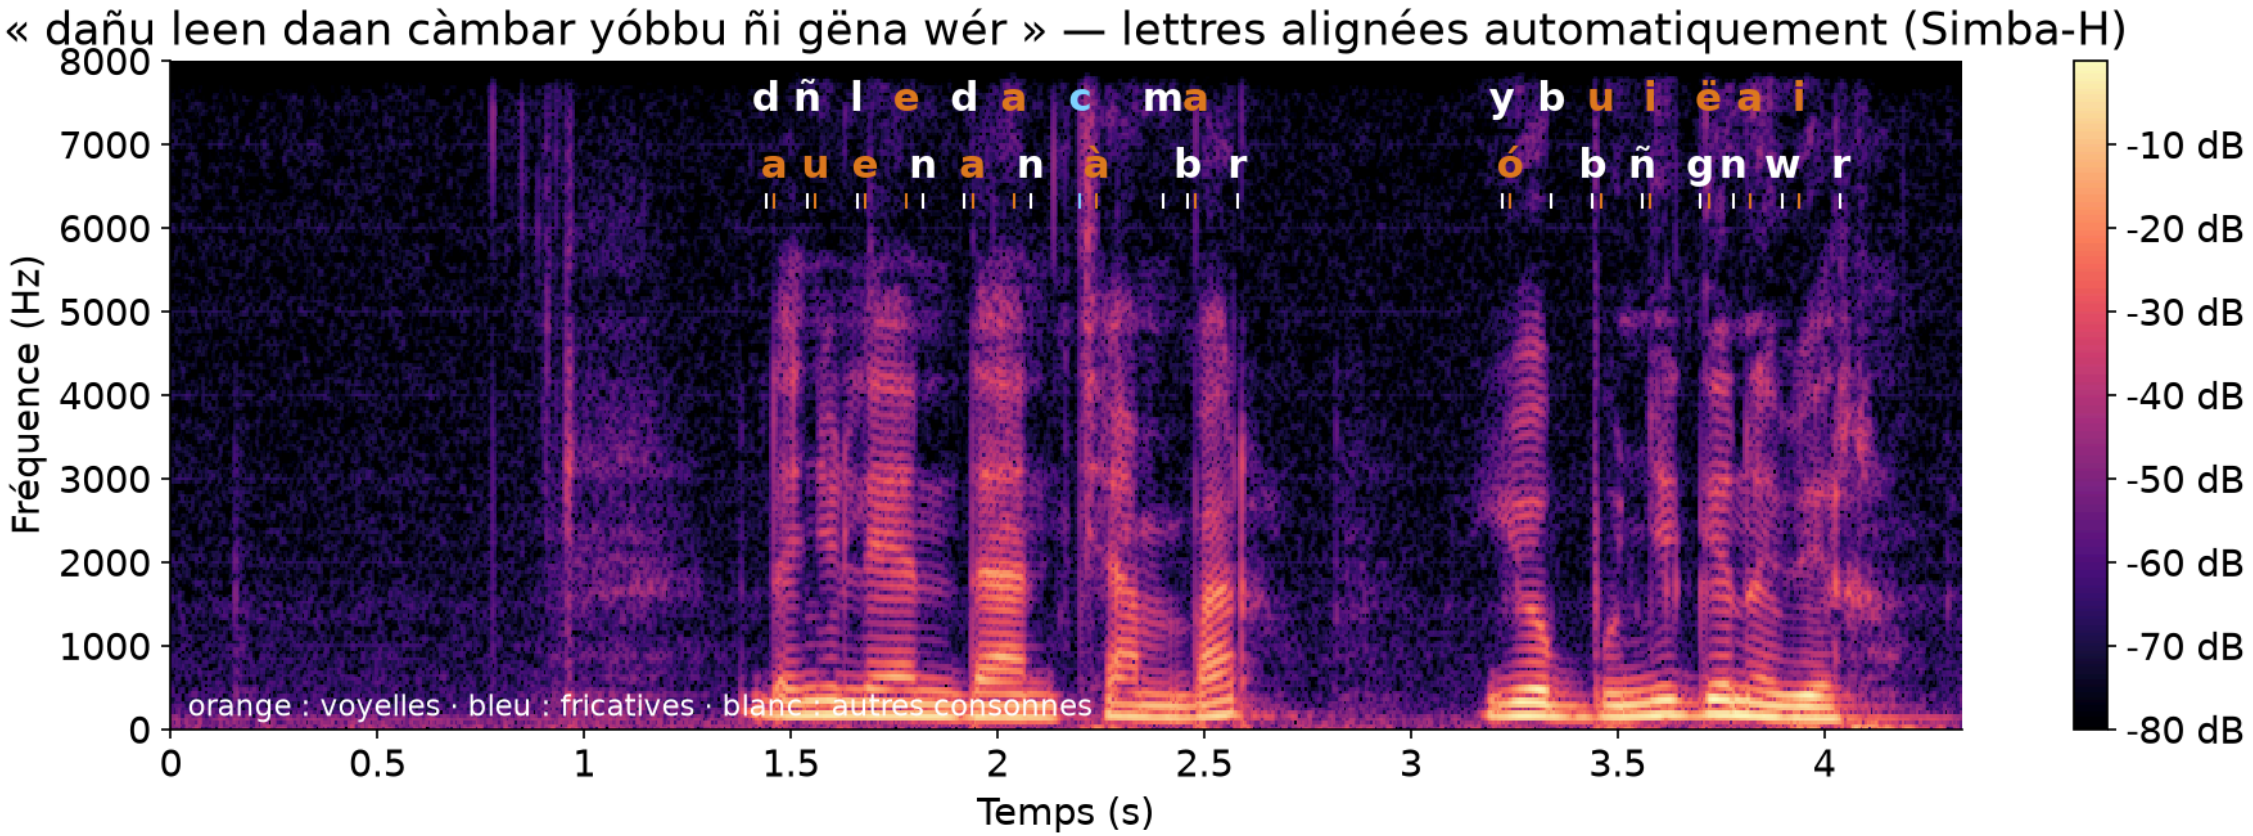
Le compromis temps / fréquence



Courte = précise en **temps** · Longue = précise en **fréquence** · Standard parole : **25 ms / 10 ms**

4. Lire un spectrogramme

Un spectrogramme se lit



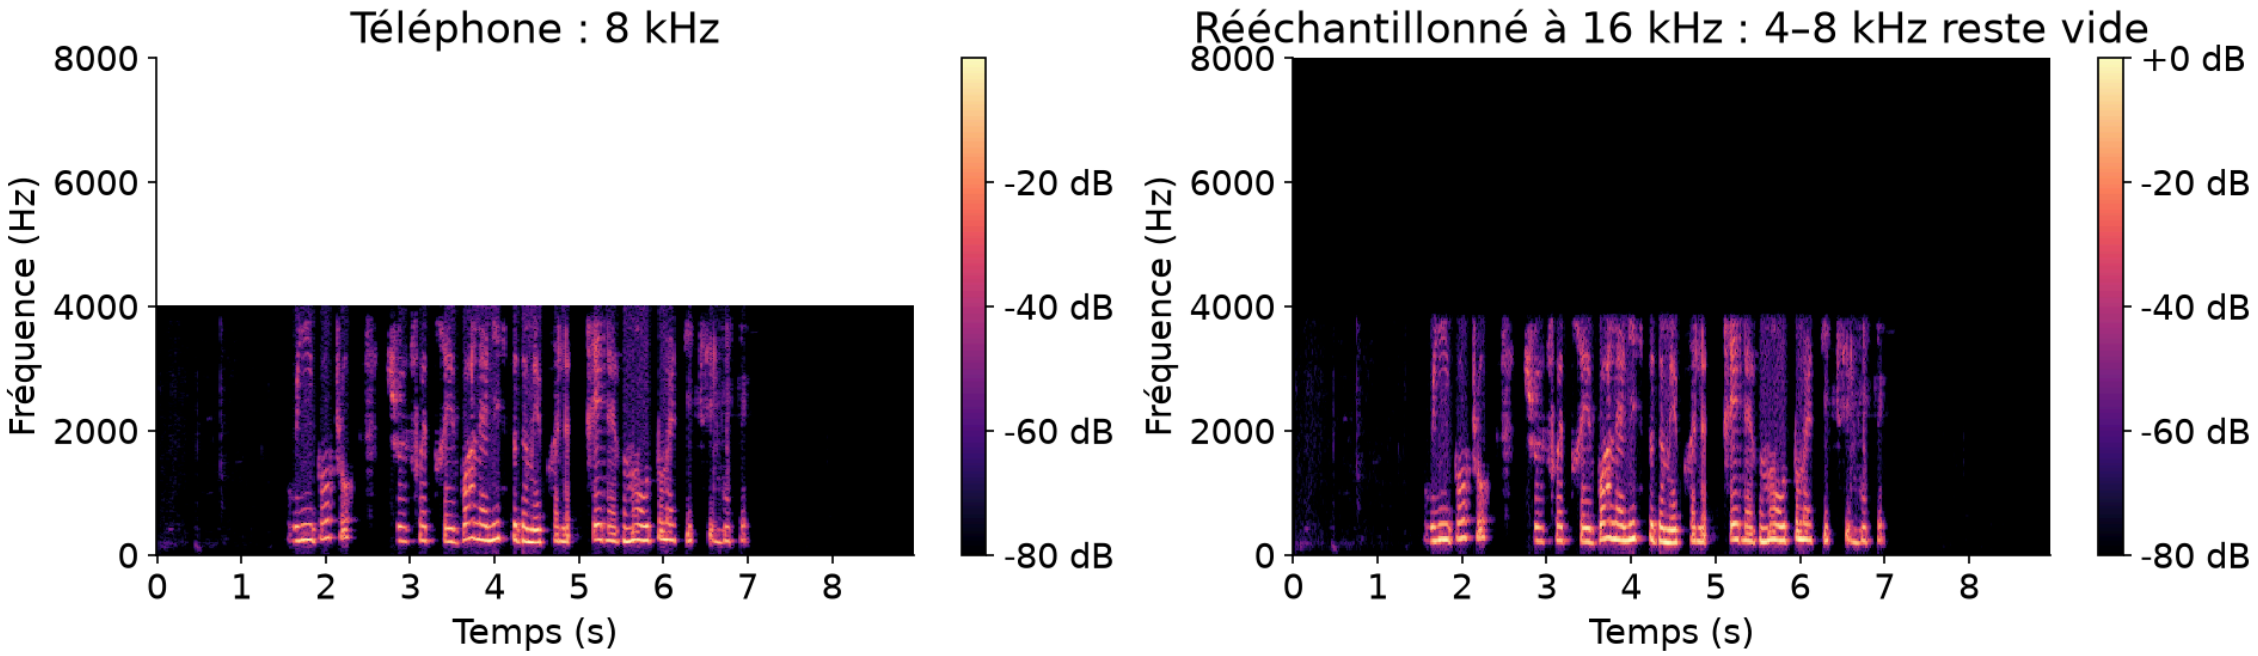
Grille de lecture

Motif	Son
Bandes horizontales + stries régulières	**voyelle** (formants + harmoniques)
Bruit diffus dans les aigus	**fricative** (s, f, x)
Silence puis barre verticale	**occlusive** (p, t, k, b, d)
Énergie surtout < 500 Hz	**nasale** (m, n, ñ)
Stries qui s'écartent / se resserrent	la **F0** monte / descend → **ton**
Durée d'une voyelle ou d'une tenue	**longueur**, **gémination** (wolof)

Les défauts se voient aussi

Défaut	Signature
Saturation	stries verticales parasites, crêtes plates
Secteur	ligne à **50 Hz** (+ 100, 150…)
MP3 bas débit	aigus coupés net
Téléphone	**rien au-dessus de 4 kHz**
Bruit de fond	voile permanent, même dans les silences
Réverbération	les sons « bavent »

La téléphonie : ce qui est perdu



Rééchantillonner **ne recrée pas** l'information · fricatives (s, f, x) plus difficiles

❓ Question éclair

Sur un spectrogramme, une zone de bruit diffus entre 4 et 8 kHz, sans stries horizontales, c'est plutôt…

- A. une voyelle
- B. une fricative comme *s*
- C. un silence
- D. une nasale

🛠️ Atelier 2A — Du signal au spectrogramme

Notebook : `S2_NB01_signal_spectrogramme` · **45 min** · binômes (sur **vos** enregistrements TP1)

1. 🟢 Inspecter vos fichiers (fs, canaux, format)
2. 🟢 **Entendre** le repliement ; 🔵 prédire la fréquence repliée
3. 🔵 Quantification ; 🔴 vérifier « 6 dB par bit »
4. 🟢 Forme d'onde ; 🔵 spectre d'une voyelle
5. 🟢 Spectrogramme avec curseurs ; 🔵 tableau du compromis temps/fréquence
6. 🟢 Paire minimale ; téléphone 8 kHz · 🔴 codec MP3

☕ Pause — 10 minutes

Reprise à **1:30** : Mel, MFCC et prétraitement