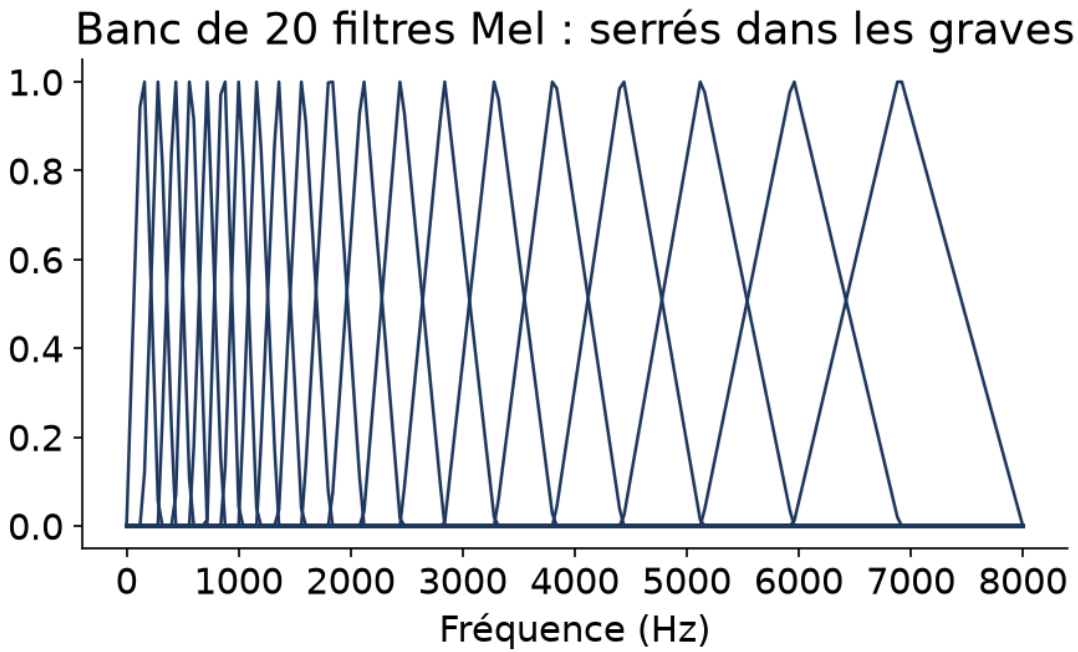
Features & prétraitement

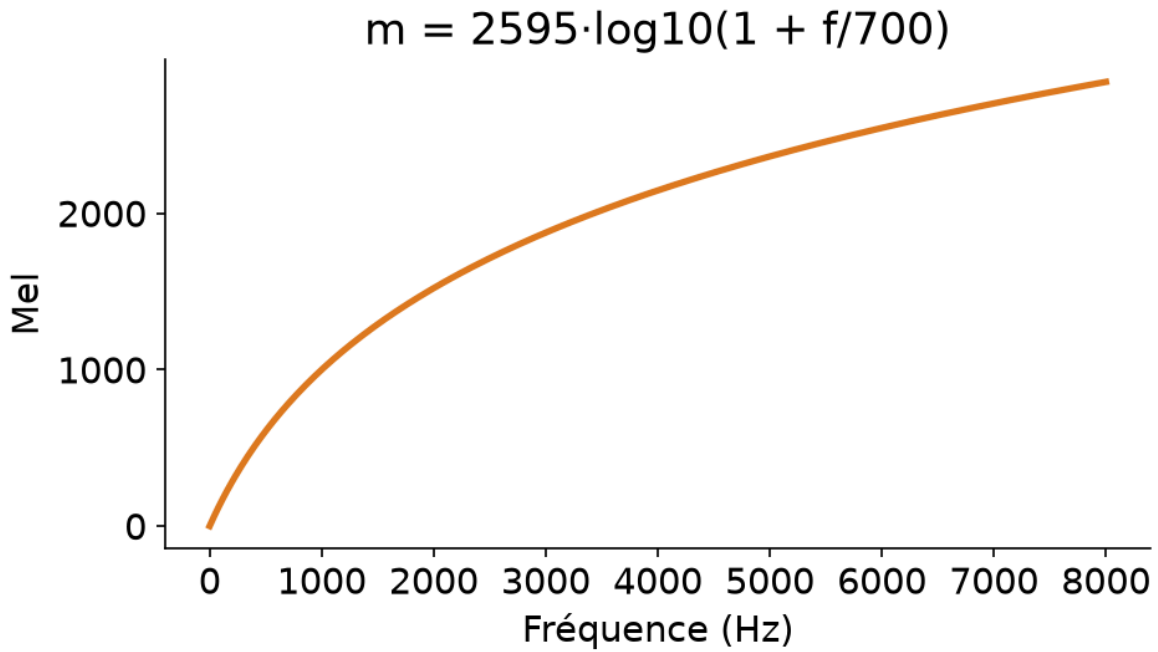
Module 1 — Session 2 · Partie B

Ce que voient les modèles — et comment leur préparer l'audio

6. Ce que « voient » les modèles

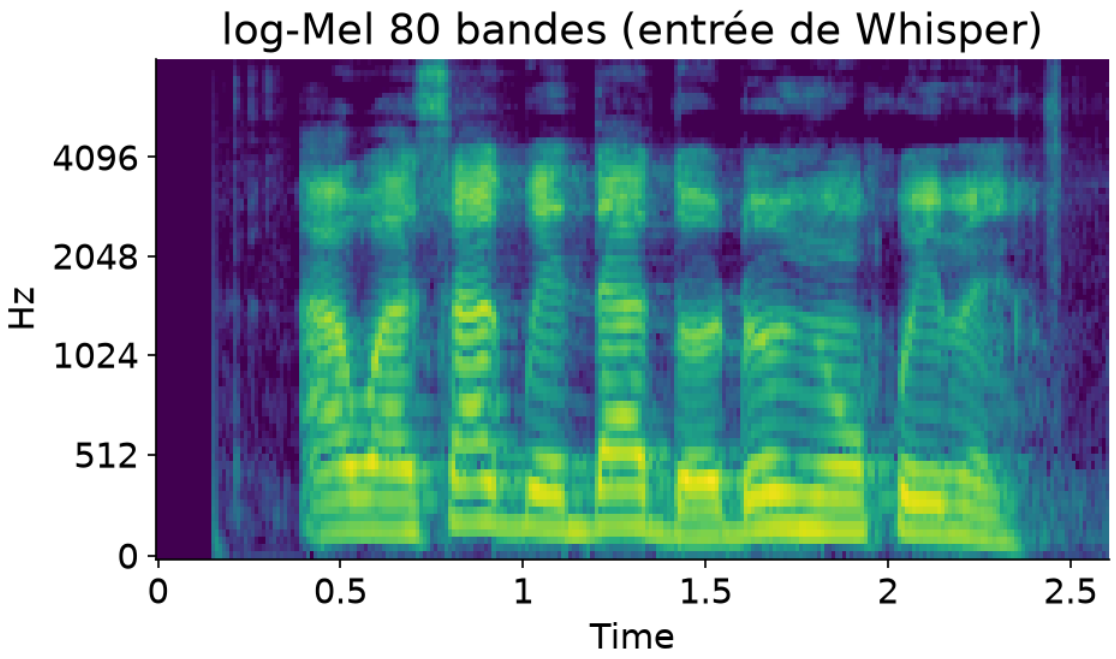
L'échelle Mel : comme notre oreille

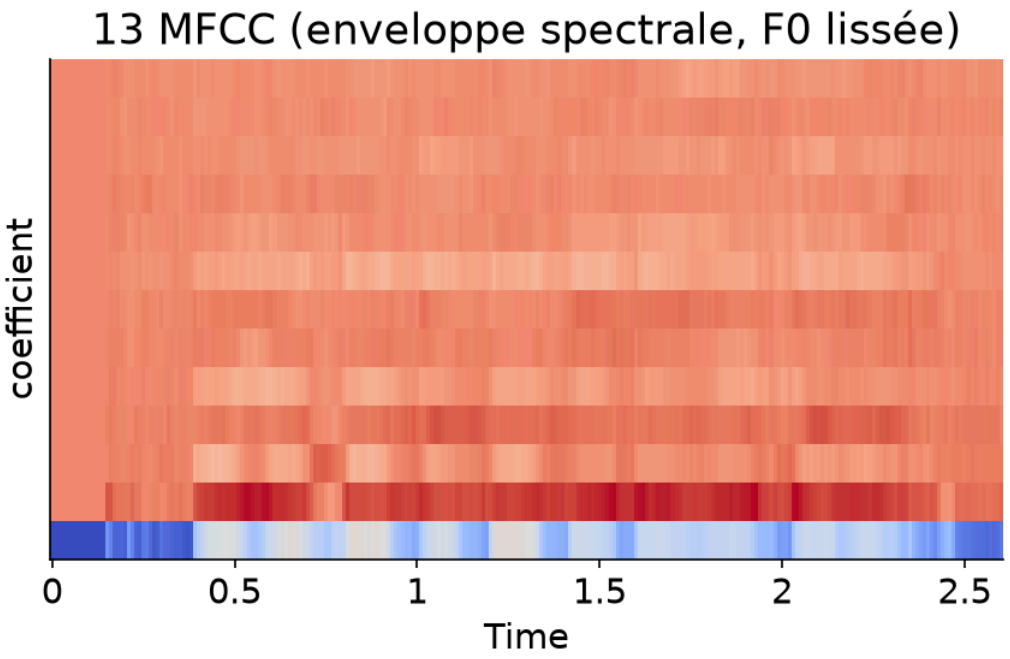




Filtres **serrés dans les graves**, larges dans les aigus · log → **log-Mel**

log-Mel vs MFCC





Trois façons de nourrir un modèle

Entrée	Pour 1 s	Pas	Modèles	F0 conservée ?
Signal brut 16 kHz	16 000 nombres	— (sortie 20 ms)	wav2vec2, HuBERT, **Simba-H**, **MMS**	oui
log-Mel 80 bandes	80 × 100	10 ms	**Whisper**, beaucoup de TTS	partiellement
MFCC 13 (39 avec Δ)	13 × 100	10 ms	HMM-GMM, mots-clés embarqués	**non**

Whisper : fenêtre de **30 s → 80 × 3 000**

7. Le prétraitement

D'abord : diagnostiquer

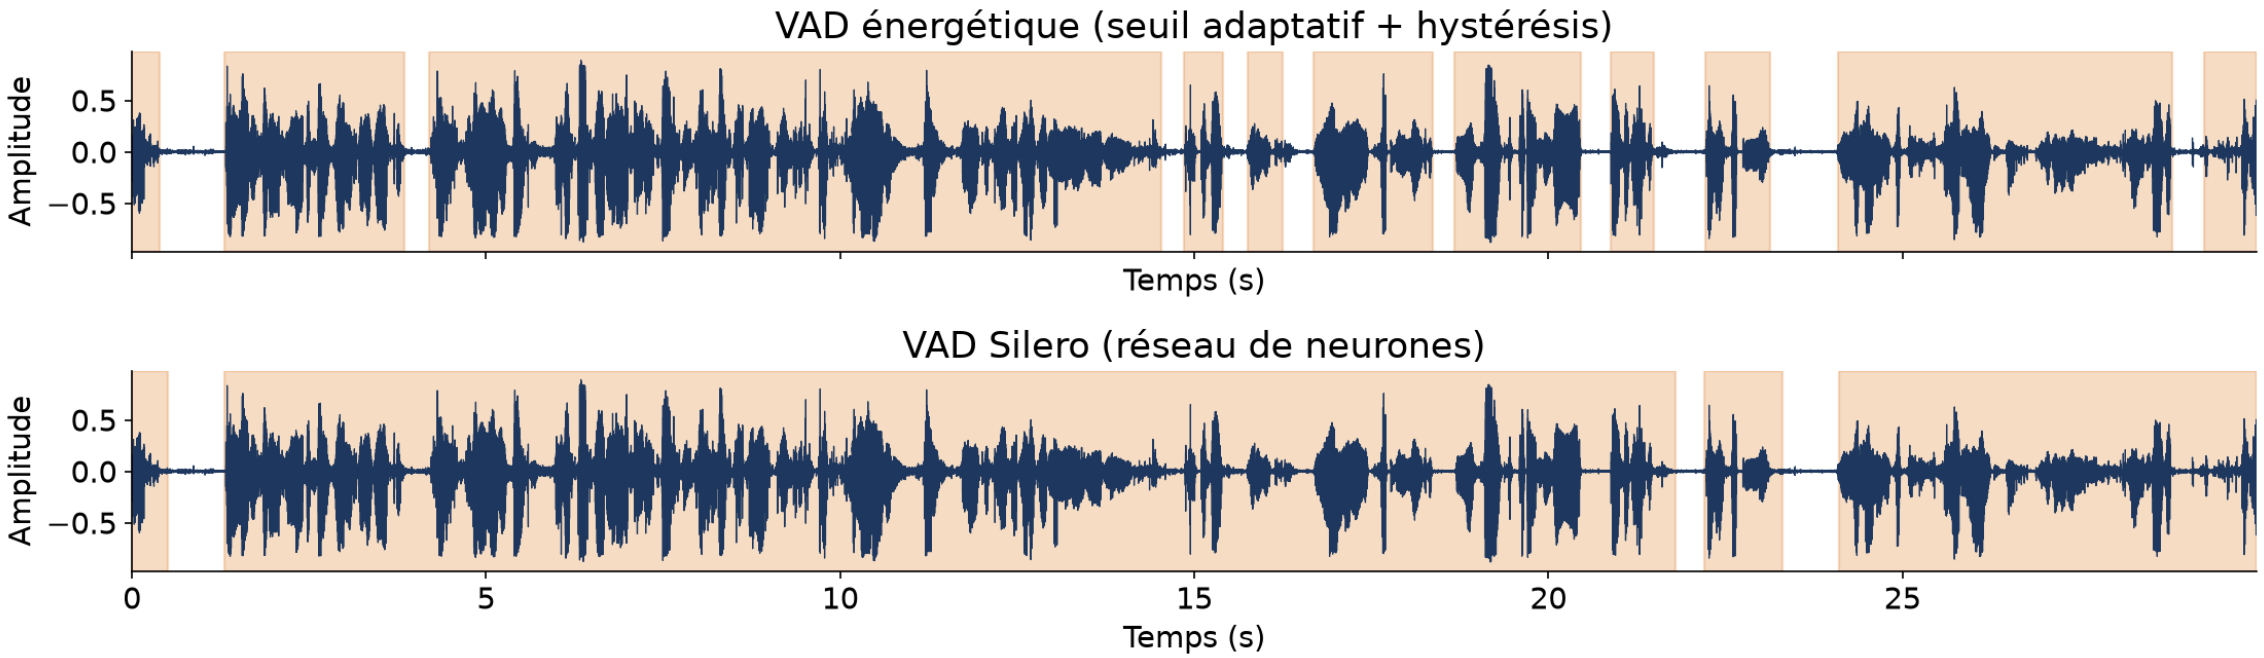
Mesure	Bon	Problème
fs, canaux	16 kHz, mono (ou convertible)	8 kHz : info perdue
Crête	−6 à −1 dBFS	0 dBFS : saturation
RMS	−25 à −15 dBFS	< −35 : trop faible
DC offset	≈ 0	décalage constant
SNR	> 20 dB	< 15 dB : ASR dégradée

Normaliser le niveau

- **Crête** → max à −1 dBFS (simple, sensible aux claquements)
- **RMS** → énergie moyenne à −20 dBFS
- **LUFS** (ITU-R BS.1770) → sonie perçue (radio, plateformes)

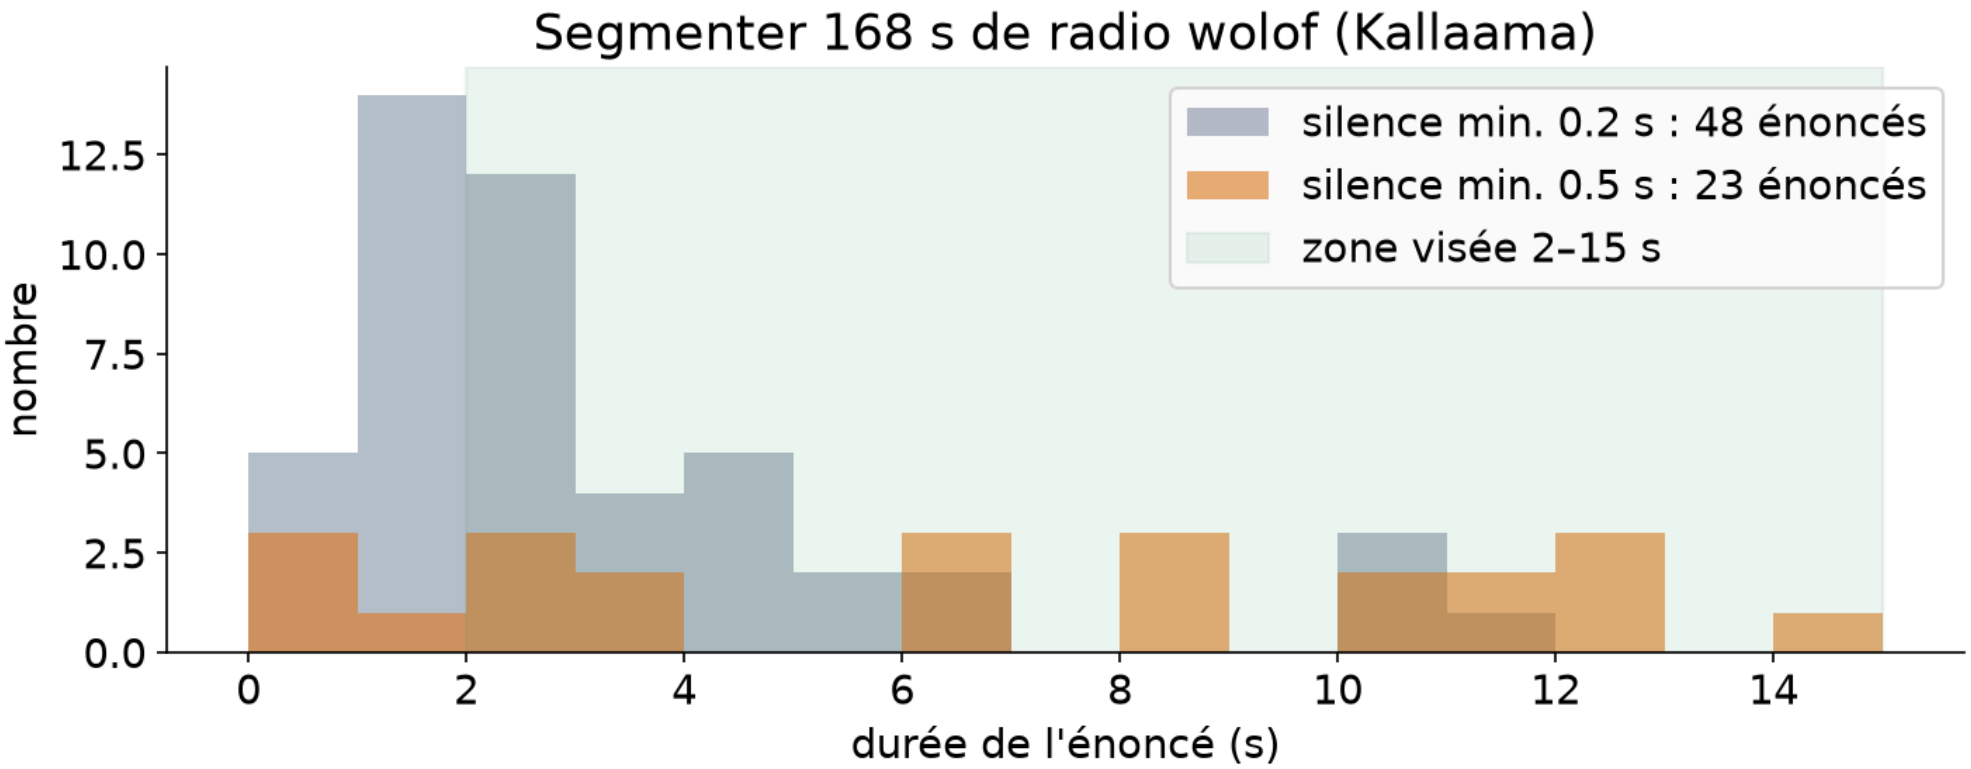
Pourquoi ? Écoute, annotation, cohérence du corpus (les modèles normalisent souvent eux-mêmes leur entrée)

Détecter la parole : VAD



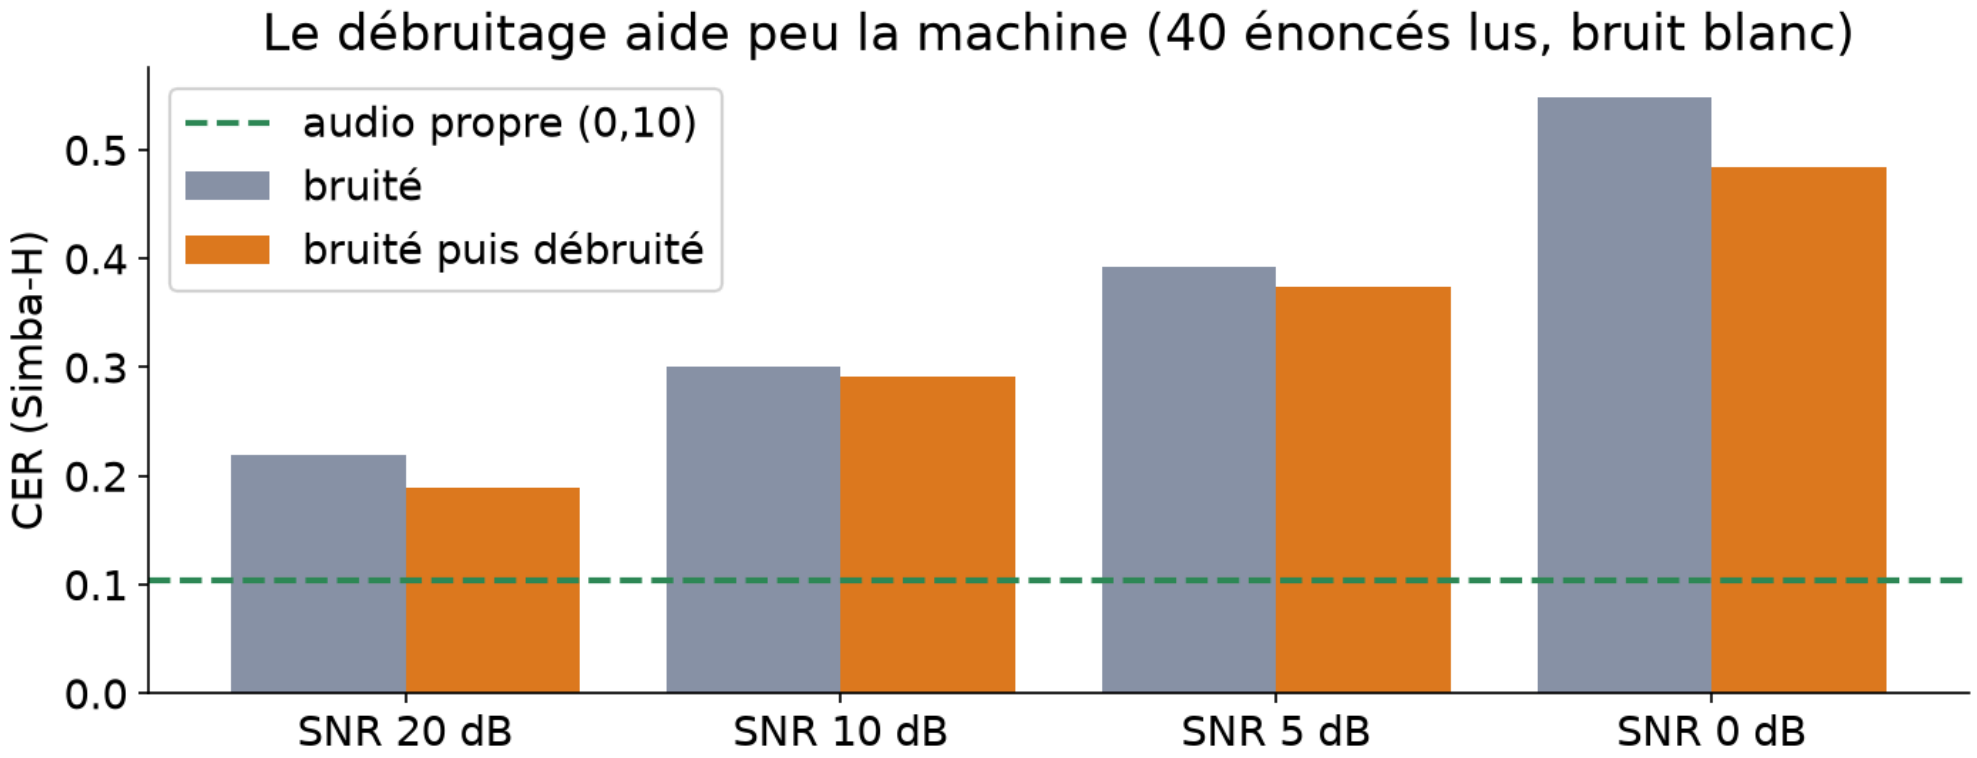
Seuil d'énergie (adaptatif, hystérésis) vs **Silero** (réseau de neurones)

Segmenter un long enregistrement



Cible ASR : énoncés de **2 à 15 s** (Whisper : 30 s max) → **régler** le silence minimal

Débruiter ? Mesurez d'abord !



Agréable à l'oreille ≠ utile à la machine → **artefacts** · Préférer : bien enregistrer + **augmentation de données**

Le pipeline de référence

```
charger (mono) → 16 kHz → retirer DC → normaliser (−1 dBFS) → couper les silences + marge 0,2 s
   → [VAD Silero + segmentation 2–15 s] → [débruitage : seulement si mesuré utile]
   → WAV 16 bits + rapport qualité
```

```python
from m1utils.preprocess import PreprocessConfig, preprocess
segments, rapport = preprocess(y, sr, PreprocessConfig(vad="silero", normalization="peak"))
```

? Question éclair

Pourquoi un modèle à base de **MFCC** est-il désavantagé pour le **fongbe** ?

- A. Les MFCC ne fonctionnent qu'en anglais
- B. Les MFCC lissent les harmoniques : l'information de F0 (les tons) est en grande partie perdue
- C. Les MFCC exigent du 44,1 kHz
- D. Les MFCC suppriment les voyelles

🛠️ TD2 — Lecture de spectrogrammes

15 min · binômes · 6 figures (lien dans le chat)

1. 🟢 Délimiter silence / voyelle / fricative / occlusive
2. 🔵 Estimer la F0 à partir des harmoniques
3. 🟢 Associer 2 spectrogrammes aux mots d'une paire minimale
4. 🟢 Repérer le défaut d'enregistrement
5. 🔵 Bande étroite ou bande large ?
6. 🔴 Estimer F1/F2 d'une voyelle

🛠️ Atelier 2B — Votre pipeline de prétraitement

Notebook : `S2_NB02_pipeline_pretraitement` · **40 min** · binômes (inversez les rôles)

1. 🟢 Diagnostiquer (dBFS, saturation, SNR)
2. 🔵 Coder la normalisation crête · 🟢 couper les silences
3. 🔵 Coder un **VAD** maison, comparer à Silero
4. 🟢 Segmenter **168 s de radio wolof** ; 🔵 régler la segmentation
5. 🟢 **Le débruitage aide-t-il l'ASR ?** On mesure !
6. 🔵 Assembler `mon_preprocess` · 🟢 préparer votre corpus pour S3

🗣️ Restitution (2:45 – 2:55)

- Votre meilleur **avant / après** (écoute + spectrogramme)
- Votre réglage de **segmentation** et pourquoi
- Le débruitage : **verdict mesuré**

? Quiz de sortie (5 min)

8 questions — lien dans le chat

📝 TP2 — Analyse & nettoyage de mon corpus (≈ 2 h 30)

1. 🟢 Analyser **3 paires minimales** (spectrogramme + F0 / durée) : vos voix + le pack
2. 🔵 Appliquer **votre pipeline** à tous vos fichiers TP1 → `clean/` (paramètres justifiés)
3. 🔵 Segmenter l'enregistrement long fourni → énoncés de 2–15 s
4. 🟢 **Rapport qualité** : durée, SNR avant/après, saturation, décision + 3 recommandations
5. 🔴 Bonus : **MFCC from scratch** en NumPy vs librosa

Dépôt : `TP2_{nom}/` sur Drive · **Échéance** : veille de la session 3, 18 h

La prochaine fois — Session 3

La reconnaissance vocale (ASR), en trois séances

- **3·1** : le Transformer pas à pas — Whisper reconstruit à la main
- **3·2** : du Conformer à Omnilingual ASR — wav2vec 2.0, HuBERT, Simba
- **3·3** : la CTC à la main et le **banc d'essai** sur vos langues

Merci ! 🙏

📚 Pour aller plus loin

- Jurafsky & Martin, *Speech and Language Processing* (3e éd.), chapitres phonétique et features
- McFee et al. (2015), *librosa* · Jadoul et al. (2018), *Parselmouth*
- Silero VAD · Park et al. (2019), *SpecAugment*

Support écrit : `module1/session2/cours/S2_cours.md`